



**TECHNISCHE
UNIVERSITÄT
DRESDEN**

Fakultät Mathematik Institut für Numerik, Professur für Numerik der Optimalen Steuerung

OPTIMIERUNG UND NUMERIK

Dr. John Martinovic

Wintersemester 2019/20

Autor : Eric Kunze
E-Mail : `eric.kunze@mailbox.tu-dresden.de`

Inhaltsverzeichnis

1	Einführung	2
1.1	Aufgabenstellung und Grundbegriffe	2
1.2	Beispiele zur kontinuierlichen Optimierung	3
1.2.1	Transportoptimierung	3
1.2.2	Kürzeste euklidische Entfernung	4
1.3	Beispiele zur diskreten Optimierung	4
1.3.1	Das Rucksackproblem	4
1.3.2	Das Bin-Packing-Problem	5
1.3.3	Standortplanung	6
1.3.4	Quadratisches Zuordnungsproblem	7
2	Grundlagen	8
2.1	Existenz von Lösungen	8
2.2	Optimalitätsbedingungen	10
2.3	Das Lemma von FARKAS	14
3	Lineare Optimierung	17
3.1	Basislösungen und Ecken	17
3.2	Das primale Simplex-Verfahren	19
3.2.1	Phase 2 des Simplex-Verfahrens	20
3.2.2	Phase 1 (Hilfsfunktionsmethode)	24
3.2.3	Der Simplexalgorithmus	24
3.3	Das duale Simplexverfahren	25
3.4	Dualität	27
3.5	Transportoptimierung	30
3.5.1	Problemstellung	30
3.5.2	Erzeugung eines ersten Transportplans	33
3.5.3	Der Transportalgorithmus	34
4	Diskrete Optimierung	37
4.1	Spaltengenerierung	37
4.2	Die Methode Branch & Bound	38
4.2.1	Grundlagen	38
4.2.2	Allgemeiner B&B-Algorithmus	39
4.2.3	Beispiele für B&B-Verfahren	40

Kapitel 1

EINFÜHRUNG

1.1 Aufgabenstellung und Grundbegriffe

Es seien $G \subseteq \mathbb{R}^n$ und $f: G \rightarrow \mathbb{R}$ gegeben. In dieser Vorlesung betrachten wir Optimierungsaufgaben (OA) der Form

$$f(x) \rightarrow \min \quad \text{bei } x \in G \quad (1.1)$$

Man nennt

- f die **Zielfunktion**,
- G den **zulässigen Bereich** und
- ein $x \in G$ **zulässigen Punkt** (oder zulässige Lösung).

Ein zulässiger Punkt $x^* \in G$ heißt **optimal** (oder Lösung oder optimale Lösung), wenn für alle $x \in G$ die Ungleichung

$$f(x^*) \leq f(x) \quad (1.2)$$

gilt. Falls das Problem (1.1) lösbar ist, so wird mit $f^* = f(x^*)$ der **Optimalwert** bezeichnet. Das Problem (1.1) ist ein

- **unrestringiertes** (oder freies) Optimierungsproblem, wenn $G = \mathbb{R}^n$ gilt,
- andernfalls (d.h. für $G \neq \mathbb{R}^n$) ein **restringiertes** Problem

und außerdem eine

- **diskrete** (oder ganzzahlige) OA (engl. integer program), falls jede Variable eine diskreten Menge angehört
- **kontinuierliche** (oder stetige) OA, falls alle Variablen stetige Werte annehmen
- **gemischt ganzzahlige** OA, wenn sowohl stetige als auch diskrete Variablen vorkommen.

Gilt in (1.1) $f(x) = c^\top x$ für ein $c \in \mathbb{R}^n$ und ist G durch lineare Bedingungen beschreibbar, so heißt (1.1) **linear**. In diesem Fall lässt sich (1.1) schreiben als

$$c^\top x \rightarrow \min \quad \text{bei } Ax = a, Bx \leq b \quad (1.3)$$

mit geeigneten Matrizen A und B sowie Vektoren a und b .

Gerade für (gemischt) ganzzahlige OA kann die Lösung der Originalaufgabe schwierig sein. Eine verwandte, jedoch im Allgemeinen leichter zu lösende Aufgabe kann in diesen Fällen wie folgt erhalten werden:

Definition 1.1

Wir betrachten die Optimierungsaufgaben

$$(P) \quad f(x) \rightarrow \min \quad \text{bei } x \in D \cap E$$

$$(Q) \quad g(x) \rightarrow \min \quad \text{bei } x \in E$$

(Q) heißt **Relaxation** zu (P) falls $g(x) \leq f(x)$ für alle $x \in D \cap E$ gilt. In vielen Fällen wird dabei $g = f$ gewählt.

Der Optimalwert der Relaxation kann als Näherung (bzw. untere Schranke) für den tatsächlichen Optimalwert von (P) genutzt werden. Meistens liefert die Lösung von (Q) jedoch keinen zulässigen Punkt für (P).

Satz 1.1

Ist \bar{x} eine Lösung von (Q) und gilt $\bar{x} \in D$ sowie $f(\bar{x}) = g(\bar{x})$, dann löst \bar{x} auch (P).

Beweis. siehe Übung □

Definition 1.2

Seien (Q1) und (Q2) Relaxationen zu (P). (Q1) heißt **stärker** (oder strenger) als (Q2), wenn die Schranke (d.h. der Optimalwert) von (Q1) größer oder gleich der Schranke (Optimalwert) von (Q2) für jede Instanz von (P) ist.

Anmerkung. Zur Erklärung des Begriffes "Instanz" betrachte das folgende Beispiel.

- Problemklasse: $c^\top x \rightarrow \min$
- Instanz der Problemklasse: $x_1 + 2x_2 - 3x_3 \rightarrow \min$

Eine Instanz ist also eine konkrete Belegung.

1.2 Beispiele zur kontinuierlichen Optimierung

1.2.1 Transportoptimierung

→ lineare Optimierung

Es gebe Erzeuger $i \in I = \{0, \dots, n\}$ und Verbraucher $j \in J = \{1, \dots, n\}$. Weiterhin seien die Kosten c_{ij} für den Transport einer Einheit von i nach j sowie der Vorrat $a_i > 0$ und der Bedarf $b_j > 0$ für alle i und j gegeben. Wie muss der Transport organisiert werden, damit die Gesamtkosten minimal sind?

Für jedes mathematische Modell einer OA braucht man

- geeignete Variablen ($\rightarrow x$)
- Zielfunktion ($\rightarrow f$)
- Nebenbedingungen ($\rightarrow G$)

Variablen $x_{ij} \geq 0$ für alle $i \in I$ und $j \in J$ beschreibe die Einheiten, die von i nach j transportiert werden.

Zielfunktion $f(x) = \sum_{i \in I} \sum_{j \in J} c_{ij} x_{ij} \rightarrow \min$

Nebenbedingungen

- Kapazitätsbeschränkung der Erzeuger $i \in I$: $\sum_{j \in J} x_{ij} \leq a_i \quad (i \in I)$
- Bedarfserfüllung von Verbrauchern $j \in J$: $\sum_{i \in I} x_{ij} \geq b_j \quad (j \in J)$

Somit können wir als Modell formulieren:

$$\begin{aligned} f(x) = \sum_{i \in I} \sum_{j \in J} c_{ij} x_{ij} \rightarrow \min \quad & \text{bei } \sum_{j \in J} x_{ij} \leq a_i \quad (i \in I), \\ & \sum_{i \in I} x_{ij} \geq b_j \quad (j \in J), \\ & x_{ij} \geq 0 \quad ((i, j) \in I \times J) \end{aligned}$$

1.2.2 Kürzeste euklidische Entfernung

→ nichtlineare Optimierung

Gegeben seien ein Punkt $\tilde{x} \in \mathbb{R}^n$ und eine Menge $G \subseteq \mathbb{R}^n$ mit $x \notin G$. Wir betrachten die folgende OA:

$$f(x) = \|x - \tilde{x}\|_2^2 \rightarrow \min \quad \text{bei } x \in G$$

Ist $G \neq \emptyset$ und abgeschlossen, so existiert eine Lösung. Ist G zusätzlich konvex, so ist die Lösung sogar eindeutig.

Weitere Beispiele und Theorie sind in der Vorlesung "Kontinuierliche Optimierung" im Master Mathematik zu erfahren.

1.3 Beispiele zur diskreten Optimierung

1.3.1 Das Rucksackproblem

Gegeben seien ein Behälter ("Rucksack") mit Kapazität $b \in \mathbb{Z}_+ := \{0, 1, \dots\}$ sowie m Teile, die jeweils durch ein Gewicht $a_i \in \mathbb{Z}_+$ und einen Nutzen $c_i \in \mathbb{Z}_+$ beschrieben werden ($i = 1, \dots, m$). Aus dieser Menge von Objekten ist eine nutzenmaximale Teilmenge auszuwählen.

Variablen

$$x_i := \begin{cases} 1 & \text{wenn Teil } i \text{ eingepackt wird} \\ 0 & \text{sonst} \end{cases} \quad (i = 1, \dots, m)$$

Zielfunktion $f(x) = \sum_{i=1}^m c_i x_i \rightarrow \max$

Nebenbedingungen Kapazitätsbedingung: $\sum_{i=1}^m a_i x_i \leq b$

Als Modell können wir somit formulieren:

$$f(x) = \sum_{i=1}^m c_i x_i \rightarrow \max \quad \text{bei} \quad \sum_{i=1}^m a_i x_i \leq b \quad \text{und} \quad x_i \in \{0, 1\} \quad (i = 1, \dots, m)$$

Aufgrund der binären Gestalt der Variablen wird das Problem auch als 0/1-Rucksackproblem bezeichnet. Im Gegensatz dazu ist beim klassischen Rucksackproblem jedes Teil mehrfach nutzbar. In diesem Fall ist $x_i \in \mathbb{Z}_+$ zu fordern.

1.3.2 Das Bin-Packing-Problem

Gegeben seien (sehr große) Anzahl an Behältern der Kapazität L sowie b_i Teile des Gewichts oder Volumens ℓ_i mit $i \in I = \{1, \dots, m\}$. Man ermittle die minimale Anzahl an Behältern, die benötigt wird, um alle Objekte zu verstauen. Jede Packung (eines Behälters) kann als Vektor $a = (a_1, \dots, a_m) \in \mathbb{Z}_+^m$ geschrieben werden, wobei a_i angibt, wie oft das Teil i benutzt wird. Ein solcher Vektor ist eine zulässige Packung, wenn

$$\sum_{i=1}^m \ell_i a_i \leq L$$

ist.

Modell nach Kantorovich Wir benötigen

- eine obere Schranke $u \in \mathbb{Z}_+$ für die maximal benötigte Anzahl an Behältern
- $y_k = \begin{cases} 1 & \text{wenn Rucksack } k \text{ benutzt wird} \\ 0 & \text{sonst} \end{cases} \quad (k = 1, \dots, u)$
- $x_{ik} \in \mathbb{Z}_+$, die angeben, wieviele Objekte vom Typ i in Rucksack k gepackt werden
 $((i, k) \in \{1, \dots, m\} \times \{1, \dots, u\})$

Daraus ergibt sich nun folgendes Modell:

$$\begin{aligned} f^{\text{Kant}}(x, y) = \sum_{k=1}^u y_k \rightarrow \min \quad & \text{bei} \quad \sum_{k=1}^u x_{ik} = b_i \quad (i = 1, \dots, m) \\ & \sum_{i=1}^m x_{ik} \ell_i \leq L \cdot y_k \quad (k = 1, \dots, u) \\ & y_k \in \{0, 1\} \quad (k = 1, \dots, u) \\ & x_{ik} \in \mathbb{Z}_+ \quad ((i, k) \in \{1, \dots, m\} \times \{1, \dots, u\}) \end{aligned}$$

Die erste Nebenbedingung sorgt dafür, dass alle Teile gepackt werden; die zweite Nebenbedingung liefert die Einhaltung der Kapazität unter Berücksichtigung, dass nur bepackte Behälter gezählt werden.

Es kann stets $u = \sum_{i=1}^m b_i$ gewählt werden. Das Auffinden besserer Schranken ist im Allgemeinen schwierig. Eine Relaxation kann z.B. durch $y_k \in [0, 1]$ und $x_{ik} \in \mathbb{R}_+$ erhalten werden. Diese liefert jedoch keine guten Näherungen.

Modell von Gilmore & Gomory Es seien J eine Indexmenge aller zulässigen Packungen und $x_j \in \mathbb{Z}_+$ ($j \in J$) die Häufigkeit, wie oft ein Behälter nach dem durch j angegebenen Schema $a^j = (a_1^j, \dots, a_m^j)$ mit $\ell^\top a^j \leq L$ gefüllt wird. Daraus ergibt sich folgendes Modell:

$$f^{GG}(x) = \sum_{j \in J} x_j \rightarrow \min \quad \text{bei} \quad \sum_{j \in J} a_i^j \cdot x_j = b_i \quad (i = 1, \dots, m)$$

$$x_j \in \mathbb{Z}_+ \quad (j \in J)$$

Die Nebenbedingung sorgt dafür, dass alle Teile gepackt werden.

Es gibt im Allgemeinen exponentiell viele zulässige Packungen a^j ($j \in J$), deren Koeffizienten allesamt in den Nebenbedingungen benötigt werden.

Eine Relaxation erhält man zum Beispiel durch $x_j \in \mathbb{R}_+$. Diese stetige Relaxation ist sehr gut; man vermutet, dass folgende Bedingung gilt:

$$f^{GG,*} - f_{\text{relax}}^{GG,*} < 2$$

Erfreulicherweise gibt es zum Gilmore-Gomory-Modell äquivalente Formulierungen, die mit einer polynomiellen Zahl von Variablen arbeiten und eine ebenso gute stetige Relaxation besitzen (z.B. Flussmodelle).

1.3.3 Standortplanung

Ein Dienstleister möchte neue Filialen aufbauen, um seine Kunden $k \in K := \{1, \dots, m\}$ zu versorgen. Dabei sind aus der Menge $S := \{1, \dots, n\}$ mögliche Standorte, die neuen Standorte so auszuwählen, dass der Bedarf aller Kunden befriedigt wird und die Gesamtkosten minimal sind.

Wir benötigen

- $c_s > 0 \dots$ Fixkosten für den Aufbau von Standort $s \in S$
- $d_{ks} > 0 \dots$ Kosten, um den Kunden $k \in K$ (vollständig) von Standort $s \in S$ zu beliefern.

Variablen:

- $x_s = \begin{cases} 1 & \text{wenn Standort } s \in S \text{ gebaut wird} \\ 0 & \text{sonst} \end{cases}$
- $y_{ks} \geq 0 \dots$ Anteil des Bedarfs des Kunden $k \in K$, der vom Standort $s \in S$ bedient wird (implizit: $y_{ks} \in [0, 1]$)

Modell zur Standortplanung:

$$f(x, y) = \underbrace{\sum_{s \in S} x_s c_s}_{\text{Fixkosten}} + \underbrace{\sum_{s \in S} \sum_{k \in K} y_{ks} d_{ks}}_{\text{variable Kosten}} \rightarrow \min$$

bei

$$\begin{aligned} \sum_{s \in S} y_{ks} &= 1 & (k \in K) \\ y_{ks} &\leq x_s & (s \in S, k \in K) \\ x_s &\in \{0, 1\} & (s \in S) \\ y_{ks} &\geq 0 & (k \in K, s \in S) \end{aligned}$$

1.3.4 Quadratisches Zuordnungsproblem

Es sollen n Personen auf n Räume verteilt werden. Person i muss Person j c_{ij} mal am Tag treffen. Außerdem habe Büro k von Büro ℓ die Entfernung $d_{k\ell} > 0$. Wird Person i das Büro k zugewiesen und Person j das Büro ℓ , so ergibt sich eine Gesamtwegstrecke von $2c_{ij}d_{kl}$ (beachte Hin- und Rückweg). Gesucht ist die wegminimale Belegung der Büros.

Variablen: $x_{ik} = \begin{cases} 1 & \text{wenn Person } i \text{ das Büro } k \text{ zugewiesen wird} \\ 0 & \text{sonst} \end{cases} \quad (i, k) \in \{1, \dots, n\} \times \{1, \dots, n\}$

Zielfunktion:

$$f(x) = \sum_{i=1}^n \sum_{k=1}^n \sum_{\substack{j=1 \\ j \neq i}}^n \sum_{\substack{\ell=1 \\ \ell \neq k}}^n x_{j\ell} x_{ik} \cdot 2c_{ij}d_{kl} \rightarrow \min$$

bei

$$\begin{aligned} \sum_{i=1}^n x_{ik} &= 1 & (k = 1, \dots, n) & \quad \text{Büro } k \text{ bekommt genau einen Einwohner} \\ \sum_{k=1}^n x_{ik} &= 1 & (i = 1, \dots, n) & \quad \text{Person } i \text{ bekommt genau ein Büro} \\ x_{ik} &\in \{0, 1\} & (i, k) \in \{1, \dots, n\} \times \{1, \dots, n\} \end{aligned}$$

Weitere Beispiele sind in der Vorlesung "Diskrete Optimierung" (Master Mathe) zu finden..

Kapitel 2

GRUNDLAGEN

2.1 Existenz von Lösungen

Wir betrachten die Optimierungsaufgabe

$$f(x) \rightarrow \min \quad \text{bei } x \in G \quad (2.1)$$

wobei folgende Bedingungen erfüllt seien:

- f ist stetig (zumindest auf G)
- G ist kompakt
- $G \neq \emptyset$

Satz 2.1 (Weierstrass)

Unter diesen Voraussetzungen existiert ein $\bar{x} \in G$ mit

$$f^* := f(\bar{x}) \leq f(x) \quad \forall x \in G$$

Beweis. Sei $f^* := \inf_{x \in G} f(x)$. Wegen $G \neq \emptyset$, finden wir eine Folge $\{f_k\}_{k \in \mathbb{N}} \subseteq \mathbb{R}$ mit $f_k = f(x_k) \geq f^*$ mit $x_k \in G$ für alle $k \in \mathbb{N}$ und $\lim_{k \rightarrow \infty} f_k = f^*$. Die daraus resultierende Folge $\{x_k\}_{k \in \mathbb{N}}$ besitzt wegen der Kompaktheit von G eine konvergente Teilfolge $\{\widetilde{x}_k\}_{k \in \mathbb{N}} \subseteq \{x_k\}_{k \in \mathbb{N}}$ mit $\lim_{k \rightarrow \infty} \widetilde{x}_k = \bar{x} \in G$ (Abgeschlossenheit von G). Die Stetigkeit von f ergibt nun $\lim_{k \rightarrow \infty} f(\widetilde{x}_k) = f(\bar{x}) = f^*$ (insbesondere $f^* \in \mathbb{R}$) □

Beispiel 2.1

(1) Satz 2.1 anwendbar (G kompakt, Minimum existiert):

$$f(x_1, x_2) = x_1 - x_2 \rightarrow \min \quad \text{bei } x_1^2 + 4x_2^2 \leq 1$$

Der zulässige Bereich ist eine Ellipse mit Rand.

(2) Satz 2.1 nicht anwendbar (G unbeschränkt, kein Minimum, $f^* = -\infty$):

$$f(x_1, x_2) = x_1 - x_2 \rightarrow \min \quad \text{bei } x_1^2 + 4x_2^2 \geq 1$$

(3) Satz 2.1 nicht anwendbar (G unbeschränkt, kein Minimum, $f^* = 0$)

$$f(x_1, x_2) = \frac{1}{x_1} \rightarrow \min \quad \text{bei } x_2 \leq \frac{1}{x_1}, x_1 \geq 1, x_2 \geq 0$$

(4) Satz 2.1 nicht anwendbar (G unbeschränkt, Minimum existiert, $f^* = -1$)

$$f(x_1, x_2) = -\frac{1}{x_1} \rightarrow \min \quad \text{bei } x_2 \leq \frac{1}{x_1}, x_1 \geq 1, x_2 \geq 0$$

Offensichtlich besitzen also nicht alle Optimierungsaufgaben eine (globale) Lösung, insbesondere deshalb, weil Bedingung (??) ziemlich stark ist. Stattdessen hat sich in der Literatur auch der folgende "schwächere" Lösungsbegriff etabliert.

Definition 2.1

Ein zulässiger Punkt $\bar{x} \in G$ heißt lokale Lösung von (2.1), falls ein $\rho > 0$ existiert mit

$$f(\bar{x}) \leq f(x) \quad \forall x \in G \cap B_\rho(\bar{x})$$

wobei $B_\rho(\bar{x}) := \{x \in \mathbb{R}^n : \|x - \bar{x}\|_2 \leq \rho\}$ die offene Kugel vom Radius ρ um \bar{x} ist.

Bemerkung 2.1

Jede globale Lösung ist auch lokale Lösung. Die Umkehrung ist im Allgemeinen nicht korrekt.

Sofern eine globale Lösung existiert, ist diese in der Menge der lokalen Lösungen enthalten. Die Betrachtung lokaler Lösungen ist damit im Allgemeinen ausreichend. Für eine spezielle Klasse von Optimierungsaufgaben sind beide Lösungskonzepte sogar äquivalent. Dazu betrachten wir die folgenden Definitionen:

Definition 2.2 (Konvexität)

- (1) $G \subseteq \mathbb{R}^n$ ist konvex, falls für alle $x, y \in G$ gilt

$$[x, y] := \{x(\lambda) \in \mathbb{R}^n : x(\lambda) = (1 - \lambda)x + \lambda y, \lambda \in [0, 1]\} \subseteq G$$

- (2) Sei G konvex. Die Funktion $f: G \rightarrow \mathbb{R}$ heißt konvex, wenn gilt

$$f(x + \lambda(y - x)) \leq f(x) + \lambda(f(y) - f(x))$$

für alle $x, y \in G$ und $\lambda \in [0, 1]$.

- (3) Sei G konvex. Eine Funktion $f: G \rightarrow \mathbb{R}$ heißt streng konvex, wenn gilt

$$f(x + \lambda(y - x)) < f(x) + \lambda(f(y) - f(x))$$

für alle $x, y \in G$ und $\lambda \in [0, 1]$.

Ausgehend von diesen Begrifflichkeiten erhalten wir das folgende Resultat:

Satz 2.2

Sei $G \subseteq \mathbb{R}^n$ eine konvexe Menge und $f: G \rightarrow \mathbb{R}$ eine konvexe Funktion.

- (1) Jede lokale Lösung ist gleichzeitig auch globale Lösung von (2.1).
- (2) Falls f sogar streng konvex ist, dann existiert höchstens eine Lösung.

Beweis. (1) Sei $\tilde{x} \in G$ eine lokale Lösung von (2.1). Wir nehmen an, dass dies jedoch keine globale Lösung ist, d.h. es existiert ein $\bar{x} \in G$ mit $f(\bar{x}) < f(\tilde{x})$. Wegen der Konvexität von G gilt dann $x(\lambda) = \tilde{x} + \lambda(\bar{x} - \tilde{x}) \in G$ für alle $\lambda \in [0, 1]$. Mit der Konvexität von f folgt

letzlich

$$f(x(\lambda)) = f(\tilde{x} + \lambda(\bar{x} - \tilde{x})) \stackrel{f \text{ konvex}}{\leq} f(\tilde{x}) + \underbrace{\lambda}_{>0} \underbrace{(f(\bar{x}) - f(\tilde{x}))}_{<0} < f(\tilde{x}) \quad \forall \lambda \in (0, 1]$$

Somit ist \tilde{x} keine lokale Lösung im Widerspruch zur Annahme.

- (2) Seien x, y zwei voneinander verschiedene Lösungen., d.h. $f(x) = f(y) = f^*$. Wir erhalten $x(\lambda) \in G$ für alle $\lambda \in [0, 1]$ und

$$f(x(\lambda)) = f(x + \lambda(y - x)) \stackrel{f \text{ streng konvex}}{<} f(x) + \lambda \underbrace{(f(y) - f(x))}_{=0}$$

Somit ist x keine Lösung. □

Für konvexe Optimierungsaufgaben sind lokale und globale Lösungen also äquivalent. Als wichtigen Spezialfall konvexer Mengen halten wir die folgende Darstellung fest.

Aussage 2.3

Sei G gegeben durch

$$G := \{x \in \mathbb{R}^n : g_i(x) \leq 0, i \in I, h_j(x) = 0, j \in J\}$$

Dann gilt: falls alle Funktionen g_i ($i \in I$) konvex und alle Funktionen h_j ($j \in J$) affin-linear sind, dann ist G konvex.

Beweis. Seien $x, y \in G$ und $\lambda \in (0, 1)$. Zur Klärung der Konvexität, stellt sich die Frage, ob $x(\lambda) \in G$?

$$\begin{aligned} g_i(x(\lambda)) &= g_i(x + \lambda(y - x)) \leq g_i(x) + \lambda(g_i(y) - g_i(x)) = \underbrace{1 - \lambda}_{>0} \underbrace{g_i(x)}_{\leq 0} + \underbrace{\lambda}_{>0} \underbrace{g_i(y)}_{\leq 0} \\ &\leq 0 \\ h_j(x(\lambda)) &= h_j(x + \lambda(y - x)) = A_j(x + \lambda(y - x)) + b_j = (1 - \lambda)A_jx + \lambda A_jy + b_j \\ &= (1 - \lambda) \underbrace{[A_jx + b_j]}_{h_j(x)=0} + \lambda \underbrace{[A_jy + b_j]}_{h_j(y)=0} \\ &= 0 \end{aligned}$$

Somit ist $x(\lambda) \in G$ und G also konvex. □

Jeder zulässige Bereich einer linearen Optimierungsaufgabe (\nearrow Kapitel 3) hat diese Gestalt.

2.2 Optimalitätsbedingungen

Definition 2.3

Eine Menge $K \subseteq \mathbb{R}^n$ heißt **Kegel**, falls gilt:

$$x \in K \Rightarrow \lambda x \in K \quad \forall \lambda \geq 0$$

Ein Kegel K ist ein **konvexer Kegel**, falls K eine konvexe Menge bzw. falls gilt

$$x, y \in K \Rightarrow x + y \in K$$

für alle $x, y \in K$. Der **Kegel der zulässigen Richtungen** $Z(\tilde{x})$ ist definiert durch

$$Z(\tilde{x}) := \{d \in \mathbb{R}^n \mid \exists \bar{t} := \bar{t}(\tilde{x}, d) > 0 \text{ sodass } \tilde{x} + td \in G \quad \forall t \in [0, \bar{t}]\}$$

Für Optimierungsaufgaben ist der Kegel der zulässigen Richtungen von großer Bedeutung.

Aussage 2.4 (notwendiges Optimalitätskriterium)

Ist f auf G stetig differenzierbar und $\tilde{x} \in G$ ein lokales Minimum. Dann gilt

$$\nabla f(\tilde{x})^\top \cdot d \geq 0 \quad \forall d \in Z(\tilde{x}) \quad (2.2)$$

Ist G konvex, dann erhält man die Bedingung

$$\nabla f(\tilde{x})^\top (x - \tilde{x}) \geq 0 \quad \forall x \in G \quad (2.3)$$

Beweis. Sei \tilde{x} ein lokales Minimum und $d \in Z(\tilde{x})$ eine zulässige Richtung. Dann existiert gemäß Definition ein \bar{t} , sodass $\tilde{x} + td \in G$ für alle $t \in [0, \bar{t}]$ gilt. Weil außerdem \tilde{x} eine lokale Lösung ist, gibt es $\rho > 0$ mit $\rho < \bar{t}$ sodass $f(\tilde{x} + td) \geq f(\tilde{x})$ für $t \in (0, \rho)$ gilt. Aus dieser Ungleichung folgt

$$\frac{f(\tilde{x} + td) - f(\tilde{x})}{t} \geq 0 \quad \forall t \in (0, \rho)$$

Durch Grenzwertbildung $t \rightarrow 0$ auf beiden Seiten erhält man mithilfe der Definition der Richtungsableitung und der Stetigkeit von f die Behauptung (2.2). Für konvexe Mengen gilt stets $x - \tilde{x} \in Z(\tilde{x})$ für $x \in G$, also folgt (2.3). \square

Dieses Kriterium sagt aus, dass im Punkt \tilde{x} alle Richtungsableitungen (bezüglich zulässiger Richtungen) nicht-negativ sind, d.h. es keine zulässige Abstiegsrichtung gibt.

Bemerkung 2.2

Ein Punkt, der die Bedingung (2.2) erfüllt, heißt **stationärer Punkt**.

Bemerkung 2.3

Bei der freien Minimierung (d.h. für $G = \mathbb{R}^n$) ergibt sich wegen $Z(\tilde{x}) = \mathbb{R}^n$ für alle $\tilde{x} \in G$ die notwendige Bedingung

$$\tilde{x} \text{ ist lokales Minimum} \Rightarrow \nabla f(\tilde{x}) = 0$$

Wähle dafür $d \in \{\pm e^i\}_{i=1}^n$.

Für konvexe Optimierungsaufgaben gilt auch die Umkehrung des Resultats der vorherigen Aussage.

Aussage 2.5 (hinreichendes Optimalitätskriterium)

Es seien $G \subseteq \mathbb{R}^n$ sowie $f: G \rightarrow \mathbb{R}$ konvex und stetig differenzierbar. Falls ein $\tilde{x} \in G$ existiert, welches der Bedingung (2.3) genügt, dann ist \tilde{x} (globales) Minimum von (2.1).

Beweis. Wenn f konvex und stetig differenzierbar ist und gilt

$$f(x) \geq f(\tilde{x}) + \nabla f(\tilde{x})^\top (x - \tilde{x}) \quad \forall x \in G$$

Wegen (2.3) folgt unmittelbar die (globale) Optimalität. Ausführlicher: siehe Übung. □

Im Fall polyedrischer zulässiger Mengen $G \subseteq \mathbb{R}^n$ (wie z.B. in der linearen Optimierung) kann die Bedingung (2.2) präzisiert werden, da dann $Z(x)$ eine einfache Struktur besitzt.

Definition 2.4

$G \subseteq \mathbb{R}^n$ heißt **polyedrisch**, falls eine Darstellung $G = \{x \in \mathbb{R}^n : Ax \leq b\}$ für eine geeignete Matrix A und einen geeigneten Vektor b existiert. Hierbei gilt

$$Ax \leq b \quad :\Leftrightarrow \quad \forall i \in I = \{1, \dots, n\} : a_i^\top x = \sum_{j=1}^n a_{ij}x_j \leq b_i$$

Bemerkung 2.4

Eine polyedrische Menge G ist konvex und abgeschlossen, aber im Allgemeinen nicht beschränkt. Implizit können in der Beschreibung von G aus Definition 2.4 auch Gleichungsrestriktionen enthalten sein.

Definition 2.5

Für $x \in G$ ist die **Indexmenge der aktiven Restriktionen** definiert durch

$$I_0(x) := \left\{ i \in I : a_i^\top x = b_i \right\}$$

Sei nun ein zulässiger Punkt $x \in G$ gegeben. Damit eine beliebige Richtung $d \in \mathbb{R}^n$ zulässig ist, muss ein $\bar{t} > 0$ existieren, sodass $x + td \in G$ für alle $t \in [0, \bar{t}]$ gilt. Für einen polyedrischen Bereich G ist dies äquivalent zu

$$\forall i \in I : a_i^\top (x + td) \leq b_i \quad \Leftrightarrow \quad \forall i \in I : ta_i^\top d \leq b_i - a_i^\top x$$

für alle $t \in [0, \bar{t}]$.

- Für alle inaktiven Restriktionen (also solche $a_i^\top x < b_i$) wäre $ta_i^\top d \leq b_i - a_i^\top x$ zu erfüllen. Egal, welchen Wert $a_i^\top d$ annimmt, es kann stets eine hinreichend kleine Schrittweite (im Sinne der Definition einer zulässigen Richtung) gefunden werden. Somit schränken inaktive Restriktionen die möglichen Richtungen $d \in \mathbb{R}^n$ *nicht* ein.
- Für aktive Restriktionen (also $a_i^\top x = b_i$) erhält man $ta_i^\top d \leq 0$, also (wegen $t > 0$) $a_i^\top d \leq 0$.

Diese Bedingung lässt sich geometrisch interpretieren: das Skalarprodukt der zulässigen Richtungen und des Normalenvektors (nach außen gerichtet) a_i der begrenzenden Hyperebene muss kleiner oder gleich Null sein, d.h. der Schnittwinkel beider Vektoren liegt im Bereich $[\frac{\pi}{2}, \pi]$. Folglich zeigt die zulässige Richtung $d \in \mathbb{R}^n$ tatsächlich in das Innere von G .

Für einen zulässigen Punkt $x \in G$ kann somit folgende Beobachtung angegeben werden:

$$d \in Z(x) \Leftrightarrow \forall i \in I_0(x): a_i^\top d \leq 0 \quad (2.4)$$

Außerdem ist die Größe \tilde{t} (maximale Schrittweite) wohldefiniert.

$$\tilde{t} := \tilde{t} := \min \left\{ \frac{b_i - a_i^\top x}{a_i^\top d} : i \in I(x, d) \right\} \quad (2.5)$$

wobei $I(x, d) := \{i \in I: a_i^\top d > 0\}$.

Bemerkung 2.5

Falls $I(x, d) = \emptyset$, setzen wir $\tilde{t} := \infty$.

Beispiel 2.2

Wir betrachten $x := (1, 1, 1)^\top$ und die polyedrische Menge

$$G := \left\{ (x_1, x_2, x_3)^\top \in \mathbb{R}^3 : x_1 + 2x_2 + x_3 \leq 4, 3x_1 + x_2 + x_3 \leq 6, x_i \geq 0, i = 1, 2, 3 \right\}$$

Offenbar gilt $x \in G$. Wir betrachten die Richtungen

$$d^1 = (1, 1, 1)^\top \text{ und } d^2 = (-1, -2, -1)^\top$$

Als aktive Restriktionen erkennen wir $I_0(x) = \{1\}$ (da nur die erste Nebenbedingung von G mit Gleichheit erfüllt ist).

- Für $d = d^1$ gilt

$$a_i^\top d = \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}^\top \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = 4 > 0$$

Somit ist d^1 keine zulässige Richtung wegen (2.4).

- Für $d = d^2$ gilt

$$a_i^\top d = \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}^\top \begin{pmatrix} -1 \\ -2 \\ -1 \end{pmatrix} = -6 \leq 0$$

Somit ist d^2 eine zulässige Richtung wegen (2.4). Zur maximalen Schrittweite: Die Ungleichung $(3, 1, 1)^\top (x + td) \leq 6$ liefert die Bedingung $t \in [-\frac{1}{6}, \infty)$. Aus $x + td \geq 0$ folgt die Bedingung $t \leq \frac{1}{2}$. Insgesamt gilt $\tilde{t} = \frac{1}{2}$.

Zusammengefasst erhalten wir das folgende Resultat:

Folgerung 2.6

Sei G polyedrisch, d.h. $G = \{x \in \mathbb{R}^n : Ax \leq b\}$ und $f: G \rightarrow \mathbb{R}$ stetig differenzierbar. Ist \tilde{x} eine lokale Lösung von (2.1), so gilt

$$\nabla f(\tilde{x})^\top \cdot d \geq 0 \quad \forall d \in \mathbb{R}^n \text{ mit } a_i^\top d \leq 0 \quad \forall i \in I_0(\tilde{x}) \quad (2.6)$$

Ist f zusätzlich konvex, dann gilt auch die Umkehrung.

2.3 Das Lemma von FARKAS

Das folgende Resultat besitzt vielfältige Anwendungen in der Optimierung (\nearrow Dualität).

Lemma 2.7 (Farkas)

Es seien $A \in \mathbb{R}^{m \times n}$ und $a \in \mathbb{R}^m$. Von den Systemen

(i) $Az \leq 0, a^\top z > 0$

(ii) $A^\top u = a, u \geq 0$.

ist *genau* eines lösbar.

Beweis. ■ *höchstens* eines der Systeme ist lösbar: Seien (i) und (ii) lösbar. Dann gilt

$$0 < a^\top z = A^\top u^\top z = \underbrace{u^\top}_{\geq 0} \underbrace{Az}_{\leq 0} \leq 0 \quad \text{.}$$

■ *mindestens* eines der Systeme ist lösbar — die Unlösbarkeit von (ii) impliziert die Lösbarkeit von (i): Sei (ii) nicht lösbar. Dann gilt $a \notin K := \{x = A^\top u : u \geq 0\}$, wobei K ein konvexer, abgeschlossener Kegel ist. Wir betrachten die Optimierungsaufgabe

$$f(x) = \frac{1}{2} \|a - x\|_2^2 = \frac{1}{2} (a - x)^\top (a - x) \rightarrow \min \text{ bei } x \in K$$

Dann existiert eine eindeutige (und globale) Lösung $\bar{x} \in K$ mit

$$(1) \quad \nabla f(\bar{x})^\top \bar{x} = 0 \quad (2) \quad \nabla f(\bar{x})^\top x \geq 0 \quad \forall x \in K$$

Zunächst folgt gemäß Aussage 2.4, dass $\nabla f(\bar{x})^\top (x - \bar{x}) \geq 0$ für alle $x \in K$. Durch Einsetzen von $x = \frac{1}{2}\bar{x} \in K$ und $x = 2 \cdot \bar{x} \in K$ (beachte: K ist Kegel) erhält man (1). Dies wiederum lässt sich zur notwendigen Bedingung ddazu addieren und man erhält (2). Nun zeigen wir, dass $z := a - \bar{x} \neq 0$ (wegen $a \notin K$) das System (i) löst. Es gilt $\nabla f(\bar{x}) = -z$ und damit folgt

$$0 = \nabla f(\bar{x})^\top \bar{x} = -z^\top \cdot (\bar{x} - a + a) = z^\top (z - a) \Rightarrow a^\top z = z^\top z \stackrel{z \neq 0}{>} 0$$

Weiter gilt $x \in K$ genau dann, wenn ein $u \geq 0$ existiert mit $x = A^\top u$. Aus (2) folgt dann

$$\begin{aligned} \nabla f(\bar{x})^\top x \geq 0 \quad \forall x \in K &\Rightarrow -z^\top A^\top u \geq 0 \quad \forall u \geq 0 \\ &\Rightarrow (Az)^\top u \leq 0 \quad \forall u \geq 0 \\ &\Rightarrow Az \leq 0 \quad (\text{wähle z.B. wieder } u = e^1, e^2, \dots) \end{aligned}$$

Damit löst z das System (1). □

Damit können die notwendigen Optimalitätsbedingungen (2.6) bzw. äquivalent dazu

$$\forall i \in I_0(x): a_i^\top \cdot d \leq 0 \Rightarrow \nabla f(\tilde{x})^\top \cdot d \geq 0 \quad (2.7)$$

wie folgt umformuliert werden: Offenbar ist (2.7) gleichbedeutend mit der Unlösbarkeit von

$$\nabla f(\tilde{x})^\top \cdot d < 0, \quad a_i^\top \cdot d \leq 0 \quad \forall i \in I_0(\tilde{x})$$

Wählt man also im Lemma von Farkas $a = -\nabla f(\tilde{x})$ und A bestehend aus den Zeilen a_i^\top , so folgt die Lösbarkeit des Systems

$$\nabla f(\tilde{x}) + \sum_{i \in I_0(\tilde{x})} u_i a_i = 0 \quad (u \geq 0) \quad (2.8)$$

Für konvexe Optimierungsaufgaben ist die Lösbarkeit von (2.8) sogar äquivalent dazu, dass \tilde{x} Lösung der betrachteten Aufgabe ist.

Gerade im Hinblick auf die praktische Anwendbarkeit ist (2.8) in der jetzigen Form wenig hilfreich, da \tilde{x} und damit $I_0(\tilde{x})$ unbekannt sind. Man betrachtet daher oftmals die folgende äquivalente Umformulierung:

Lemma 2.8

Sei $G := \{x \in \mathbb{R}^n: a_i^\top x \leq b_i, i \in I\}$ und $f: G \rightarrow \mathbb{R}$ stetig differenzierbar. Wenn $x \in \mathbb{R}^n$ Lösung von

$$f(x) \rightarrow \min \text{ bei } x \in G$$

ist, dann existiert ein Vektor u , sodass das Paar (x, u) das folgende System löst:

$$\begin{aligned} \nabla f(x) + \sum_{i \in I} u_i a_i &= 0 \quad u_i \geq 0, \quad a_i^\top - b_i \leq 0 \quad (i \in I) \\ u_i (a_i^\top x - b_i) &= 0 \quad (i \in I) \end{aligned} \quad (2.9)$$

Dabei beschreibt $a_i^\top - b_i \leq 0$ die Zulässigkeit von $x \in G$ und $u_i (a_i^\top x - b_i) = 0$ gleicht die zu große Indexmenge der Summe wieder aus, d.h. für inaktive Restriktionen folgt $u_i = 0$. Ist f konvex, so gilt auch die Umkehrung. Man nennt (2.9) auch ein **KKT-System**.

Bemerkung 2.6

- (1) KKT steht für KARUSH-KUHN-TUCKER.
- (2) Die Variablen u heißen **Lagrange-Multiplikatoren**.

- (3) Gibt es neben den Ungleichungen auch Gleichungsrestriktionen $a_i^\top x = b_i$ für $i = m + 1, \dots, \bar{m}$ und $\bar{m} > m$, dann erhält man das KKT-System

$$\begin{aligned} \nabla f(x) + \sum_{i=1}^m u_i a_i + \sum_{i=m+1}^{\bar{m}} u_i a_i &= 0 \\ u_i &\geq 0, a_i^\top x - b_i \leq 0 & (i = 1, \dots, m) \\ a_i^\top x - b_i &= 0 & (i = m + 1, \dots, \bar{m}) \\ u_i (a_i^\top x - b_i) &= 0 & (i = 1, \dots, m) \end{aligned} \tag{2.10}$$

Kapitel 3

LINEARE OPTIMIERUNG

Wir betrachten die Optimierungsaufgabe

$$z = c^\top x \rightarrow \min \text{ bei } x \in G := \{x \in \mathbb{R}^n : Ax = b, x \geq 0\} \quad (3.1)$$

mit $A \in \mathbb{R}^{m \times n}$, $c \in \mathbb{R}^n$, $b \in \mathbb{R}^m$. Außerdem nehmen wir an, dass $\text{rg}(A) = m$ gilt und dass $m \leq n$ erfüllt ist.

Bemerkung 3.1

- (1) G ist eine polyedrische Menge.
- (2) Alle endlich-dimensionalen linearen Optimierungsaufgaben lassen sich **Standardform** (3.1) überführen (↗ Übung).

3.1 Basislösungen und Ecken

Sei $I := \{1, \dots, n\}$. Da $\text{rg}(A) = m$, existiert eine Indexmenge $I_B \subseteq I$ mit $|I_B| = m$ derart, dass alle Spalten A^i ($i \in I_B$) linear unabhängig sind. I_B wird **Basis-Indexmenge** genannt. Mit $I_N := I \setminus I_B$ (Nichtbasis) definieren wir

$$\begin{aligned} A_B &= (A^i)_{i \in I_B} & A_N &= (A^i)_{i \in I_N} \\ c_B &= (c_i)_{i \in I_B} & c_N &= (c_i)_{i \in I_N} \\ x_B &= (x_i)_{i \in I_B} & x_N &= (x_i)_{i \in I_N} \end{aligned}$$

Dann lässt sich (3.1) schreiben als

$$z = c_B^\top x_B + c_N^\top x_N \rightarrow \min \text{ bei } A_B x_B + A_N x_N = b, x_B \geq 0, x_N \geq 0 \quad (3.2)$$

bzw. durch Auflösen der Gleichung nach x_B (beachte: A_B hat Vollrang) als

$$z = (c_N^\top - c_B^\top A_B^{-1} A_N) x_N + c_B^\top A_B^{-1} b \rightarrow \min \text{ bei } x_B = -A_B^{-1} A_N x_N + A_B^{-1} b, x_B \geq 0, x_N \geq 0 \quad (3.3)$$

Definition 3.1

Der Punkt

$$x = \begin{pmatrix} x_B \\ x_N \end{pmatrix} = \begin{pmatrix} A_B^{-1} b \\ 0 \end{pmatrix}$$

heißt **Basislösung** zu I_B . Gilt zusätzlich $A_B^{-1} b \geq 0$, dann heißt $x = (x_B, x_N)$ **zulässige Basislösung**.

Definition 3.2

Der Punkt $x \in G$ heißt **Ecke** (von G), falls aus $x = \frac{1}{2}(x^1 + x^2)$ mit $x^1, x^2 \in G$ stets $x = x^1 = x^2$ folgt.

Ecken des zulässigen Bereichs können also nicht durch andere zulässige Punkte linear kombiniert werden.

Zur Wiederholung benennen wir im Folgenden (ohne Beweis) einige Eigenschaften von Ecken und zulässigen Basislösungen.

Satz 3.1

Sei $\text{rg}(A) = m$. Dann ist jede zulässige Basislösung auch Ecke von G . Umgekehrt gibt es zu jeder Ecke mindestens eine zulässige Basislösung.

Häufig unterscheidet man zwischen

- **degenerierten** (oder entarteten) Ecken, die mehrere zulässige Basislösungen besitzen
- **nicht-degenerierten** (oder nicht-entarteten) Ecken, die genau eine zulässige Basislösung besitzen.

Dabei gilt: Eine Ecke $x \in G$ ist genau dann degeneriert, wenn ein $i \in I_B$ mit $x_i = 0$ existiert.

Beispiel 3.1

Sei

$$G := \{x \in \mathbb{R}^n : x_1 + x_2 + x_3 = 1, \quad 2x_1 + x_2 + x_4 = 2, \quad x_1, \dots, x_4 \geq 0\}$$

Hierbei ist die Ecke $E_1 = (0, 1, 0, 1)^\top$ nicht degeneriert, da sie nur die Zerlegung $I_B = \{2, 4\}$ und $I_N = \{1, 3\}$ gestattet. Die Ecke $E_2 = (1, 0, 0, 0)^\top$ ist degeneriert, weil ein $i \in I_B$ zwangsläufig $x_i = 0$ erfüllen muss.

Satz 3.2

Sei $G \neq \emptyset$. Dann besitzt G

- (1) mindestens eine Ecke
- (2) höchstens endlich viele Ecken.

Beweis. siehe Übung

□

Satz 3.3

Ist (3.1) lösbar, dann gibt es eine Ecke von G , die (3.1) löst.

Bei linearen Optimierungsaufgaben genügt es daher die Ecken von G zu betrachten. Ist die Aufgabe lösbar, so findet man durch systematisches Abschreiten der Ecken eine Lösung. Um dabei zu erkennen, ob Optimalität vorliegt, hilft folgendes Resultat:

Aussage 3.4 (Optimalitätskriterium)

Gilt für die zulässige Basislösung $x = (x_B, x_N) = (A_B^{-1}b, 0)$ die Bedingung

$$c_N^\top - c_B^\top A_B^{-1} A_N \geq 0 \quad (3.4)$$

dann ist x Lösung von (3.1).

Beweis. Sei $x = (x_B, x_N)$ eine zulässige Basislösung. Wir zeigen zunächst:

$$Z(x) \subseteq \{d \in \mathbb{R}^n : Ad = 0, d_N \geq 0\}$$

Sei $d \in Z(x)$. Dann existiert $t > 0$ mit $A(x + td) \stackrel{!}{=} b$ (beachte die Definition von G mit Gleichheitsrestriktionen). Es gilt

$$Ax + tAd = b \Leftrightarrow b + tAd = b \stackrel{t \geq 0}{\Leftrightarrow} Ad = 0$$

Wegen $x_N = 0$ ergibt sich aus $x + td \stackrel{!}{\geq} 0$ (nach Definition von G) sofort $d_N \geq 0$. Insbesondere gilt

$$Ad = 0 \Leftrightarrow A_B d_B + A_N d_N = 0 \Leftrightarrow d_B = -A_B^{-1} A_N d_N \quad \forall d \in Z(x)$$

Damit folgt unter Berücksichtigung von (3.4)

$$\begin{aligned} \nabla f(x)^\top d &= c^\top d \\ &= c_B^\top d_B + c_N^\top d_N \\ &= -c_B^\top A_B^{-1} A_N d_N + c_N^\top d_N \\ &= \underbrace{\left(c_N^\top - c_B^\top A_B^{-1} A_N \right)}_{\geq 0} \underbrace{d_N}_{\geq 0} \geq 0 \quad \forall d \in Z(x) \end{aligned}$$

d.h. x genügt der notwendigen Optimalitätsbedingung (2.2), die hier (im konvexen Fall) auch hinreichend ist. \square

Eine entsprechende Systematik zum Abschreiten der Ecken wird im Folgenden Abschnitt behandelt.

3.2 Das primale Simplex-Verfahren

Das primale Simplexverfahren durchläuft zwei Phasen (falls nötig):

- Phase 1 besteht aus der Ermittlung einer ersten Ecke (zulässige Basislösung),
- Phase 2 aus der darauf aufbauenden Bestimmung einer optimalen Ecke.

3.2.1 Phase 2 des Simplex-Verfahrens

Wir betrachten die (erste) zulässige Basislösung (Ecke) $x = (x_B, x_N)$ und schreiben (3.3) als Simplex-Tableau:

$$\begin{array}{c|c|c} T_0 & x_N & 1 \\ \hline x_B = & P & p \\ \hline z = & q^\top & q_0 \end{array}$$

$$\begin{aligned} P &= -A_B^{-1}A_N & p &= A_B^{-1}b \\ q^\top &= c_N^\top - c_B^\top A_B^{-1}A_N & q_0 &= c_B^\top A_B^{-1}b \end{aligned} \quad (3.5)$$

Wir nehmen zunächst an, dass $x = (x_B, x_N)$ eine nicht-entartete Ecke mit $x_B = (x_1, \dots, x_m)^\top$ und $x_N = (x_{m+1}, \dots, x_n)^\top$ ist. Die hierzu gehörige Basislösung ist $x = (x_B, x_N) = (p, 0)$ und es gilt $p \geq 0$ (da zulässig). Folglich ist $x \in G$.

Frage: Wenn x nicht optimal ist – wie kann eine bessere zulässige Basislösung (Ecke) gefunden werden?

Antwort: Wahl einer zulässigen Richtung $d \in Z(x)$ mit maximaler Schrittweite, die eine Verkleinerung des Zielfunktionswerts ermöglicht.

Nach Aussage 3.4 ist x optimal, falls $q \geq 0$ gilt. Sei nun $q_\tau < 0$ für $\tau \in I_N$. Zur Konstruktion einer neuen Ecke setzen wir $x_\tau = t$ (bisher war $x_\tau = 0$). Dann folgt zunächst $x_N(t) = t \cdot e_\tau$ und wegen der Forderung $x_N(t) \geq 0$ auch $t \geq 0$. Ferner ergibt sich aus Tableau T_0 der Zusammenhang $x_i(t) = P_{i\tau} \cdot x_\tau + p_i = P_{i\tau} \cdot t + p_i$ für alle $i \in I_B$.

Insgesamt verfolgen wir ausgehend von $x = (p, 0)$ die zulässige Richtung $d \in \mathbb{R}^n$

$$d_i = \begin{cases} P_{i\tau} & i \in I_B \\ 1 & i = \tau \\ 0 & i \in I_N \setminus \{\tau\} \end{cases}$$

Die maximale Schrittweite \bar{t} erhält man wie folgt: Für jedes $i \in I_B$ ist $x_i(t) \geq 0$ zu gewährleisten. Gilt $P_{i\tau} \geq 0$, so ergibt dies keine Einschränkung für die Schrittweite (weil $p_i \geq 0, t \geq 0, P_{i\tau} \geq 0 \Rightarrow x_i(t) \geq 0$ für alle $t \geq 0$). Für $P_{i\tau} < 0$ muss hingegen $t \leq -\frac{p_i}{P_{i\tau}}$ (aus Tableauezusammenhang) gewählt werden. Die maximal mögliche Schrittweite ergibt sich folglich zu

$$t \leq \bar{t} = \bar{t}(x, d) := \min \left\{ -\frac{p_i}{P_{i\tau}} : P_{i\tau} < 0, i \in I_B \right\} \quad (3.6)$$

bzw. $\bar{t} = \infty$, falls $P_{i\tau} \geq 0$ für alle $i \in I_B$.

Aussage 3.5

Im Fall $\bar{t} = \infty$ besitzt (3.1) keine Lösung, da die Zielfunktion nach unten unbeschränkt ist.

Beweis. Wegen $\bar{t} = \infty$ gilt $x(t) \in G$ für alle $t \geq 0$. Dann liefert $q_\tau < 0$ sogleich $Z(t) =$

$$\bar{q} \cdot x_N(t) + q_0 \stackrel{x_N(t)=t \cdot e_\tau}{=} q_\tau \cdot t + q_0 \rightarrow -\infty \text{ für } t \rightarrow \infty.$$

□

Bemerkung 3.2

Die beiden Fälle

(1) $q_i \geq 0$ für alle $i \in I_N$ \leadsto Optimalität

(2) es existiert ein $\tau \in I_N$ mit $q_\tau < 0$ und $P_{i\tau} \geq 0$ für alle $i \in I_B$ \leadsto Unbeschränktheit
werden primal entscheidbar genannt.

Im sogenannten nicht-entscheidbaren Fall, d.h. falls

$$(\exists \tau \in I_N: a_\tau < 0) \wedge \left(\exists \sigma \in I_B: \bar{t} = -\frac{p_\sigma}{P_{\sigma\tau}} = \min \left\{ -\frac{p_i}{P_{i\tau}} : P_{i\tau} < 0, i \in I_B \right\} < \infty \right)$$

ergibt die (maximale) Schrittweite \bar{t} den Punkt

$$\bar{x} = x + \bar{t}d \in G \text{ mit } f(\bar{x}) = f(x) + \bar{t}q_\tau = q_0 + \bar{t}q_\tau$$

Für entartete Ecken kann man die Schrittweite $\bar{t} = 0$ erhalten. In diesem Fall ändert sich der Punkt \bar{x} nicht, aber die Menge I_N und I_B . Zum Verlassen einer (noch nicht optimalen) entarteten Ecke können mehrere Schritte nötig sein.

Satz 3.6

\bar{x} ist eine Ecke von G mit Basis-Indexmenge

$$\begin{aligned} \overline{I_B} &= \overline{I_B}(\bar{x}) := (I_B \setminus \{\sigma\}) \cup \{\tau\} \\ \overline{I_N} &= \overline{I_N}(\bar{x}) := (I_N \setminus \{\tau\}) \cup \{\sigma\} \end{aligned}$$

Um zu zeigen, dass die Matrix $\overline{A_B} := (A')_{i \in \overline{I_B}}$ regulär ist, nutzen wir das folgende Resultat.

Lemma 3.7 (Sherman / Morrison)

Es seien $B \in \mathbb{R}^{m \times m}$ regulär und $u, v \in \mathbb{R}^m$. Die Matrix $\overline{B} := B + uv^\top$ ist genau dann regulär, wenn $1 + v^\top B^{-1}u \neq 0$ erfüllt ist und dann gilt

$$\overline{B}^{-1} = B^{-1} - \frac{B^{-1}uv^\top B^{-1}}{1 + v^\top B^{-1}u}$$

Beweis. Übung oder Selbststudium (aber wird nie gefragt werden) □

Beweis (Satz 3.6). Der "Austausch" der Spalten A^τ und A^σ kann durch ein dyadisches Produkt uv^\top beschrieben werden:

$$\overline{A_B} = A_B + uv^\top \text{ mit } u = A^\tau - A^\sigma \text{ und } v = e^\sigma$$

Wegen

$$\begin{aligned} 1 + v^\top B^{-1}u &= 1 + (e^\sigma)^\top A_B^{-1} (A^\tau - A^\sigma) \\ &= 1 + (e^\sigma)^\top A_B^{-1} A^\tau - 1 && ("A^\sigma \in A_B") \\ &= -P_{\sigma\tau} \neq 0 && (P = -A_B^{-1}A_N \text{ und } "A^\tau \in A_N") \end{aligned}$$

folgt aus Lemma 3.7 die Regularität von $\overline{A_B}$. \square

Beispiel 3.2

Wir betrachten $z = -x_1 - x_2 \rightarrow \min$ bei $x_1 + 2x_2 \leq 6$, $4x_1 + x_2 \leq 10$, $x_1, x_2 \geq 0$. Um aus den Ungleichungen Gleichungsnebenbedingungen zu machen, führen wir sogenannte Schlupfvariablen $x_3, x_4 \geq 0$ ein und erhalten

$$x_1 + 2x_2 + x_3 = 6, \quad 4x_1 + x_2 + x_4 = 10, \quad x_1, x_2, x_3, x_4 \geq 0 \Rightarrow x_3 = 6 - x_1 - 2x_2 \text{ und } x_4 = 10 - 4x_1 - x_2$$

Damit liegt nun eine Optimierungsaufgabe in Standardform (3.1) vor. Notieren wir dies nun in Tableauform mit $I_N = \{1, 2\}$ und $I_B = \{3, 4\}$ (betrachte dazu $x_B = Px_N + p$):

T_0	x_1	x_2	1	
$x_3 =$	-1	-2	6	$\bar{t} = \frac{6}{1}$
$x_4 =$	-4	-1	10	$\bar{t} = \frac{10}{4}$
$z =$	-1	-1	0	

Wir können nun $\tau \in \{1, 2\}$ wählen, oBdA wählen wir hier $\tau = 1$. Für x_3 ergibt sich eine maximale Schrittwerte $\bar{t} = -\frac{p_i}{P_{i\tau}} = \frac{6}{1}$. Für x_4 ergibt sich $\bar{t} = \frac{10}{4}$. Damit wird $\sigma = 4$ gewählt.

Mit $\tau = 1$ und $\sigma = 4$ sowie $\bar{t} = \frac{5}{2}$ erhält man

$$\bar{x} = x + \bar{t}d = \begin{pmatrix} 0 \\ 0 \\ 6 \\ 10 \end{pmatrix} + \frac{5}{2} \begin{pmatrix} 1 \\ 0 \\ -1 \\ -4 \end{pmatrix} = \begin{pmatrix} \frac{5}{2} \\ 0 \\ \frac{7}{2} \\ 0 \end{pmatrix}$$

und

$$z(\bar{x}) = -\frac{5}{2}$$

Der Austausch von x_τ und x_σ im Simplextableau kann formal durch die sogenannten Austauschregeln erfolgen.

T_0	x_N	1	\implies	T_1	$x_{\tilde{N}}$	1
$x_B =$	P	p		$x_{\tilde{B}} =$	\tilde{P}	\tilde{p}
$z =$	q^\top	q_0		$z =$	\tilde{q}^\top	\tilde{q}_0

$$\tilde{I}_B = (I_B \cup \{\tau\}) \setminus \{\sigma\}$$

$$\tilde{I}_N = (I_N \cup \{\sigma\}) \setminus \{\tau\}$$

Austauschregeln:

$$\begin{aligned}
 \tilde{P}_{\sigma,\tau} &:= \frac{1}{P_{\sigma,\tau}} && \text{(Pivotelement)} \\
 \tilde{P}_{\sigma,j} &:= -\frac{P_{\sigma,j}}{P_{\sigma,\tau}} \quad (j \in I_N \setminus \{\tau\}) && \tilde{p}_\sigma = -\frac{p_\sigma}{P_{\sigma,\tau}} \quad \text{(Pivotzeile)} \\
 \tilde{P}_{i,\tau} &:= -\frac{P_{i,\tau}}{P_{\sigma,\tau}} \quad (i \in I_B \setminus \{\sigma\}) && \tilde{q}_\tau := \frac{q_\tau}{P_{\sigma,\tau}} \quad \text{(Pivotspalte)} \\
 \tilde{P}_{i,j} &:= P_{i,j} - \frac{P_{\sigma,j}}{P_{\sigma,\tau}} P_{i,\tau} \quad (i \in I_B \setminus \{\sigma\}, j \in I_N \setminus \{\tau\}) && \text{(sonstige Elemente)} \\
 \tilde{p}_i &:= p_i - \frac{p_\sigma}{P_{\sigma,\tau}} P_{i,\tau} \quad (i \in I_B \setminus \{\sigma\}) \\
 \tilde{q}_j &:= q_j - \frac{P_{\sigma,j}}{P_{\sigma,\tau}} q_\tau \quad (j \in I_N \setminus \{\tau\})
 \end{aligned}$$

Vergleiche dazu auch das Merkblatt zum Simplex-Verfahren unter

https://www.math.tu-dresden.de/~martinovic/Zusammenfassung_Simplexverfahren.pdf

Beispiel 3.3

Wir betrachten wie in Beispiel 3.2 die Optimierungsaufgabe $z = -x_1 - x_2 \rightarrow \min$ bei $x_1 + 2x_2 \leq 6$, $4x_1 + x_2 \leq 10$, $x_1, x_2 \geq 0$. mit Simplex-Starttableau:

T_0	x_1	x_2	1	
$x_3 =$	-1	-2	6	$\bar{t} = 3$
$x_4 =$	-4	-1	10	$\bar{t} = 10$
$z =$	-1	-1	0	
Kellerzeile	$-\frac{1}{2}$	*	3	= neue Pivotzeile

Nun wählen wir aber $\tau = 2$, woraus sich $\sigma = 3$ ergibt. Zur besseren Übersicht haben wir eine Kellerzeile eingeführt. Diese entspricht genau der neu berechneten Pivotzeile.

T_1	x_1	x_3	1	
$x_2 =$	$-1/2$	$-1/2$	3	(Division durch -1 * Pivot)
$x_4 =$	$-7/2$	$1/2$	7	
$z =$	$-1/2$	$1/2$	-3	
Kellerzeile	$-2/7$	$1/7$	2	

Nebenrechnung: z.B. $7 = 10 + 3 \cdot (-1)$

Im nächsten Schritt wählen wir nun $\tau = 1$ und $\sigma = 4$.

T_2	x_4	x_3	1
$x_2 =$	$1/7$	$-4/7$	2
$x_1 =$	$-2/7$	$1/7$	2
$z =$	$1/7$	$3/7$	-4

Da $\tilde{p} = \begin{pmatrix} 2 \\ 2 \end{pmatrix} \geq 0$ ist, ist die Lösung zulässig. Außerdem wissen wir wegen $\tilde{q}^\top = (1/7, 3/7) \geq 0$, dass die Lösung optimal ist. Somit ergibt sich

$$x^* = (x_1^*, x_2^*, x_3^*, x_4^*) = (2, 2, 0, 0) \text{ mit } z^* = -4$$

3.2.2 Phase 1 (Hilfsfunktionsmethode)

Wir betrachten das Problem

$$z = c^\top x \rightarrow \min \text{ bei } Ax = b, x \geq 0 \quad (3.7)$$

Ohne Einschränkung sei $b \geq 0$. Durch folgendes Hilfsproblem lässt sich eine Startecke ermitteln (sofern eine solche überhaupt existiert).

$$h = e^\top y \rightarrow \min \text{ bei } y + Ax = b, x \in \mathbb{R}_+^n, y \in \mathbb{R}_+^m \quad (3.8)$$

mit $e = (1, \dots, 1)^\top \in \mathbb{R}^m$. Eine erste Basislösung für (3.8) ist gegeben durch

$$\begin{array}{c|c|c} T_0 & x & 1 \\ \hline y = & -A & b \\ \hline h = & -e^\top A & e^\top b \end{array} \quad (3.9)$$

Satz 3.8

Das Problem (3.7) besitzt genau dann eine zulässige Lösung, wenn $h_{\min} = 0$ den Optimalwert von (3.8) darstellt.

Beweis. Offenbar gilt $h_{\min} = 0 \Leftrightarrow y = 0$.

(\Rightarrow) Besitzt (3.7) eine zulässige Lösung \tilde{x} , dann ist $\begin{pmatrix} \tilde{x} \\ 0 \end{pmatrix}$ zulässig für (3.8). Wegen $0 \leq h = e^\top \tilde{y} = 0$ folgt $h_{\min} = 0$.

(\Leftarrow) Hat man umgekehrt $h_{\min} = 0$, so gilt $\tilde{y} = 0$ für jede optimale Lösung $\begin{pmatrix} \tilde{x} \\ \tilde{y} \end{pmatrix}$ von (3.8). Aus der Zulässigkeit von $\begin{pmatrix} \tilde{x} \\ \tilde{y} \end{pmatrix}$ für (3.8) folgt dann die Zulässigkeit von \tilde{x} für (3.7). \square

3.2.3 Der Simplexalgorithmus

Mit den zuvor beschriebenen Vorgehensweisen lässt sich das Simplexverfahren zur Lösung der Optimierungsaufgabe (3.1) wie folgt algorithmisch formulieren:

- **Schritt 1** (*Initialisierung*): Ermittle eine erste zulässige Basislösung $x = (x_B^\top, x_N^\top)^\top = (p^\top, 0^\top)^\top$ mit $p = (A_B)^{-1}b \geq 0$, wobei I_B die Menge der Basisindizes ist und stelle ein erstes Simplextableau auf.
- **Schritt 2** (*Optimalitätstest*): Berechne entsprechend Aussage 3.4

$$\bar{q} := \min_{j \in I_N} q_j \quad \text{mit} \quad q_j := c_j d^\top A^j \quad (j \in I_N) \quad (3.10)$$

wobei $d^\top := c_B^\top (A_B)^{-1}$ ist. Gilt $\bar{q} \geq 0$, dann ist x Lösung von (3.1). Andernfalls sei $q_\tau = \bar{q} < 0$.

- **Schritt 3** (*Test auf Unbeschränktheit*): Gilt $P_{i\tau} \geq 0$ für alle $i \in I_B$, so ist die Aufgabe nicht lösbar ($f^* = -\infty$).
- **Schritt 4** (*Austauschschritt*): Bestimme die Pivotzeile σ gemäß

$$-\frac{p_\sigma}{P_{\sigma\tau}} = \min \left\{ -\frac{p_i}{P_{i\tau}} : \bar{P}_{i\tau} < 0, i \in I_B \right\}$$

und führe den Austauschschritt $\sigma \leftrightarrow \tau$ (Aktualisierung Simplextableau) durch. Gehe zu Schritt 2.

Bemerkung 3.3

- (i) Der Simplexalgorithmus löst Problem (3.1) nach endlich vielen Schritten exakt oder stellt dessen Unlösbarkeit fest.
- (ii) Pro Simplexschritt ist im Wesentlichen die Matrix P (der Dimension $m \times (n - m)$) zu transformieren. Für $n \gg m$ kann das recht aufwendig sein, sodass ggf. alternative Varianten des Simplexalgorithmus' (z.B. das revidierte Simplexverfahren oder die Technik der Spaltengenerierung) effizienter sind.
- (iii) Der Test auf Unbeschränktheit der Zielfunktion kann auch für jede Spalte $j \in I_N$ mit $q_j < 0$ erfolgen, sofern dies nicht zu aufwendig ist.

3.3 Das duale Simplexverfahren

Nach Aussage 3.4 ist ein Tableau

$$\begin{array}{c|c|c} T_0 & x_N & 1 \\ \hline x_B = & P & p \\ \hline z = & q^\top & q_0 \end{array}$$

optimal, wenn $p \geq 0$ und $q \geq 0$ gelten. Nach Konstruktion gilt beim primalen Simplexverfahren stets $p \geq 0$. Sei nun ein Tableau T_0 gegeben mit $q \geq 0$, aber *nicht* $p \geq 0$, d.h. es gibt eine Zeile $\sigma \in I_B$ mit $p_\sigma < 0$. Die zu T_0 gehörige Basislösung ist dann *nicht* zulässig. Mithilfe des dualen Simplexverfahrens lässt sich jedoch (unter Beibehaltung von $q \geq 0$) eine zulässige Basislösung (d.h. mit " $p \geq 0$ ") erzeugen. Entsprechend der bekannten Austauschregeln ergeben sich folgende

Bedingungen:

$$\begin{aligned}\tilde{q}_j &:= q_j - \frac{P_{\sigma,j}}{P_{\sigma,\tau}} q_\tau \stackrel{!}{\geq} 0 & \forall j \in I_N \setminus \{\tau\} \\ \tilde{q}_\tau &:= \frac{q_\tau}{P_{\sigma,\tau}} \stackrel{!}{\geq} 0 \\ \tilde{p}_\sigma &:= -\frac{p_\sigma}{P_{\sigma,\tau}} \stackrel{!}{\geq} 0\end{aligned}$$

Wegen $p_\sigma < 0$ und $q_\tau \geq 0$ ist somit ein Pivotelement mit $P_{\sigma,\tau} > 0$ zu wählen. Zur Sicherstellung von $\tilde{q}_j \geq 0$ für alle $j \in I_N \setminus \{\tau\}$ muss ferner gelten

$$\frac{q_\tau}{P_{\sigma,\tau}} = \min \left\{ \frac{q_j}{P_{\sigma,j}} : P_{\sigma,j} > 0, j \in I_N \setminus \{\tau\} \right\}$$

Die eigentlichen Austauschregeln sind analog zu denen des primalen Simplexverfahrens.

Bemerkung 3.4

Da dieses Verfahren mit einem *unzulässigen* Punkt startet, ist die Folge der Zielfunktionswerte (im Gegensatz zum primalen Simplexverfahren) nicht monoton fallend.

Bemerkung 3.5

Falls eine zulässige Basislösung gefunden wird, so ist diese zwangsläufig optimal.

Beispiel 3.4

Betrachten wir die Optimierungsaufgabe

$$\begin{aligned}z = 6x_1 + 5x_2 + 12x_3 + 8x_4 + 9x_5 \rightarrow \min \quad & \text{bei} \quad x_1 + x_3 + x_4 + x_5 \geq 300, \\ & x_2 + 2x_3 + x_4 \geq 400, \\ & x_i \geq 0 \quad \forall i = 1, \dots, 5\end{aligned}$$

Um daraus Gleichungsrestriktionen zu machen, führen wir Schlupfvariablen $x_6, x_7 \geq 0$ ein, d.h.

$$\begin{aligned}x_1 + x_3 + x_4 + x_5 &= 300 + x_6, \\ x_2 + 2x_3 + x_4 &= 400 + x_7, \\ x_i &\geq 0 \quad \forall i = 1, \dots, 7\end{aligned}$$

Daraus ergibt sich nun folgendes Tableau

T_0	x_1	x_2	x_3	x_4	x_5	1	
$x_6 =$	1	0	1	1	1	-300	
$x_7 =$	0	1	2	1	0	-400	
$z =$	6	5	12	8	9	0	$\leftarrow \sigma = 7$
Keller	0	*	-2	-1	0	400	

Zur Wahl von $\tau = 2$: $\frac{5}{1}, \frac{12}{6} = 6, \frac{8}{1} = 8$. Dabei ist 5 minimal, also $\tau = 2$. Fahren wir nun mit den weiteren Tableaus fort:

T_1	x_1	x_7	x_3	x_4	x_5	1	
$x_6 =$	1	0	1	1	1	-300	$\leftarrow \sigma = 6$
$x_2 =$	0	1	-2	-1	0	400	
$z =$	6	5	2	3	9	2000	
Keller	0	*	*	-1	0	400	

T_2	x_1	x_7	x_6	x_4	x_5	1	
$x_3 =$	1	0	1	-1	1	300	
$x_2 =$	2	1	-2	1	2	-200	$\leftarrow \sigma = 2$
$z =$	4	5	2	1	7	2600	
Keller	-2	-1	2	$\tau =$	-2	200	
				4			

T_3	x_1	x_7	x_6	x_2	x_5	1	
$x_3 =$	1	1	-1	-1	1	100	
$x_4 =$	-2	-1	2	1	-2	200	
$z =$	2	4	4	1	5	2800	

Somit ergibt sich die Lösung

$$x^* = (0, 0, 100, 200, 0, 0, 0)^\top \quad \text{und} \quad z^* = 2800$$

3.4 Dualität

Wir betrachten nun die Optimierungsaufgabe

$$\begin{aligned} c^\top x &\rightarrow \min \text{ bei } Ax \leq b \text{ und } x \in \mathbb{R}_+^n \\ I &:= \{1, \dots, m\} \text{ und } J := \{1, \dots, n\} \end{aligned} \quad (\text{P})$$

Satz 3.9 (Charakterisierungssatz)

Ein Punkt $x \in \mathbb{R}^n$ ist genau dann Lösung von (P), wenn ein $\bar{x} \in \mathbb{R}^m$ existiert, sodass insgesamt das folgende System gelöst wird:

$$A\bar{x} - b \leq 0 \quad \bar{x} \geq 0 \quad (1)$$

$$A^\top \bar{u} + c \geq 0 \quad \bar{u} \geq 0 \quad (2)$$

$$\bar{u}^\top (A\bar{x} - b) = 0 \quad \bar{x}^\top (A^\top \bar{u} + c) = 0 \quad (3)$$

Beweis. Die vorliegende Optimierungsaufgabe ist äquivalent zu

$$f(x) = c^\top x \rightarrow \min \text{ bei } \underbrace{\begin{pmatrix} A \\ -\mathbb{1}_n \end{pmatrix}}_{=\tilde{A} \in \mathbb{R}^{(m+n) \times n}} x \leq \underbrace{\begin{pmatrix} b \\ 0 \end{pmatrix}}_{=\tilde{b} \in \mathbb{R}^{m+n}} \quad (\text{P}')$$

Gemäß Lemma 2.8 ist x genau dann Lösung von (P') (und (P)), wenn ein Vektor $w = \begin{pmatrix} u \\ v \end{pmatrix} \in \mathbb{R}^{m+n}$ existiert mit

$$\begin{aligned} \nabla f(x) + \sum_{i \in I \cup J} w_i \tilde{a}_i &= 0 \\ w_i &\geq 0 & (i \in I \cup J) \\ \tilde{a}_i^\top x - \tilde{b}_i &\leq 0 & (i \in I \cup J) \\ w_i (\tilde{a}_i^\top x - \tilde{b}_i) &= 0 & (i \in I \cup J) \end{aligned} \quad (\text{KKT})$$

Trennung von I und J führt zu

$$\begin{aligned} c + \sum_{i \in I} u_i a_i + \sum_{j \in J} v_j (-e^j) &= 0 & (\text{KKT}) \\ u_i &\geq 0 & (i \in I) & v_j &\geq 0 & (j \in J) \\ a_i^\top x - b_i &\leq 0 & (i \in I) & (-e^j)^\top x - 0 &\leq 0 & (j \in J) \\ u_i (a_i^\top x - b_i) &= 0 & (i \in I) & v_j ((-e^j)^\top x - 0) &= 0 & (j \in J) \end{aligned}$$

Überführt man dieses System in eine Matrix-Vektor-Schreibweise, so ergibt sich

$$\begin{aligned} c + A^\top u - v &= 0 \\ u, v, x &\geq 0 \\ Ax - b &\leq 0 \\ u^\top (Ax - b) &= 0 \\ x^\top v &= 0 \end{aligned}$$

Durch Umstellen der ersten Gleichung nach v lässt sich diese Variable im System "eliminieren" und wir erhalten die Behauptung. \square

Definition 3.3

Das Problem

$$(D) \quad z_D = -b^\top u \rightarrow \max \quad \text{bei} \quad A^\top u \geq -c, \quad u \in \mathbb{R}_+^m \quad (3.11)$$

heißt duale Optimierungsaufgabe zu (P).

Begründung: Die Anwendung von Satz 3.9 auf (D) ergibt das selbe KKT-System wie im Falle von (P). Dazu müssen wir (D) umformulieren als Minimierungsaufgabe

$$-z_D = b^\top u \rightarrow \min \quad \text{bei} \quad -A^\top u \leq c, \quad u \in \mathbb{R}_+^m$$

(damit die selbe Form wie in Satz 3.9 vorliegt). Einsetzen in (1) - (3) ergibt

$$\begin{aligned} (1) &\leadsto -A^\top u - c \leq 0, & u &\geq 0 \\ (2) &\leadsto \left(-A^\top\right)^\top y + b \geq 0, & y &\geq 0 \\ (3) &\leadsto y^\top (-A^\top u - c) = 0, & u^\top \left(\left(-A^\top\right)^\top y + b\right) &= 0 \end{aligned}$$

Umformulierung liefert

$$\begin{aligned} (1) &\leadsto A^\top u + c \geq 0, & u &\geq 0 && \text{entspricht (2) aus System für (P)} \\ (2) &\leadsto Ay - b \leq 0, & y &\geq 0 && \text{entspricht (1) aus System für (P) mit } y = x \\ (3) &\leadsto y^\top (A^\top u + c) = 0, & u^\top (Ay - b) &= 0 && \text{entspricht (3) aus System für (P)} \end{aligned}$$

(D) liefert also dasselbe System (1) - (3) wie (P).

Satz 3.10 (schwache Dualität)

Sei x zulässig für (P) und u zulässig für (D). Dann gilt

$$-b^\top u \leq c^\top x$$

Beweis. Es gilt

$$\begin{aligned} -b^\top u &\leq (-Ax)^\top u = -x^\top A^\top u && (Ax \leq b, u \geq 0) \\ &\leq x^\top c = c^\top x && (A^\top u \geq -c, x \geq 0) \end{aligned} \quad \square$$

Satz 3.11 (starke Dualität)

Die Optimierungsaufgabe (P) ist genau dann lösbar, wenn (D) lösbar ist. Für die zugehörigen Lösungen \bar{x} und \bar{u} gilt dann

$$-b^\top \bar{u} = c^\top \bar{x}$$

also die Gleichheit der Optimalwerte.

Beweis. Der erste Teil der Aussage folgt direkt aus der Gleichheit der KKT-Systeme. Aus Eigenschaft (3) des KKT-Systems folgt dann die Gleichheit der Optimalwerte mittels

$$\bar{u}^\top (A\bar{x} - b) = 0 = \bar{x}^\top (A^\top \bar{u} + c) \Rightarrow -b^\top \bar{u} = \bar{u}^\top A\bar{x} = c^\top \bar{x} \quad \square$$

Aus dem schwachen Dualitätssatz folgt insbesondere auch, dass die Existenz eines dual (primal) zulässigen Punktes eine endliche untere (obere) Schranke für den primalen (dualen) Optimalwert liefert.

Folgerung 3.12

$$(P) \text{ lösbar} \Leftrightarrow (D) \text{ lösbar} \Leftrightarrow \exists x \geq 0, u \geq 0: Ax \leq b, A^\top u \geq -c$$

Die Bedingungen (3) im KKT-System werden **Komplementaritätsbedingungen** genannt.

zum Beispiel: $u^\top (Ax - b) = 0, x \geq 0, u \geq 0, Ax - b \leq 0$, d.h. $u_i(Ax - b)_i = 0$ für alle i .

Es ist möglich, primale und duale Aufgabe gleichzeitig innerhalb eines Tableaus zu lösen:

$$\begin{aligned} (P) \quad z_P &= c^\top x \rightarrow \min & \text{bei} \quad Ax &\leq b, x \geq 0 \\ (D) \quad z_D &= -b^\top u \rightarrow \max & \text{bei} \quad -A^\top u &\leq c, u \geq 0 \end{aligned}$$

Durch Einführen von Schlupfvariablen $s \geq 0, v \geq 0$ erhält man

$$\begin{aligned} (P) \quad z_P &= c^\top x \rightarrow \min & \text{bei} \quad s &= b - Ax, x \geq 0, s \geq 0 \\ (D) \quad -z_D &= b^\top u \rightarrow \min & \text{bei} \quad v &= c + A^\top u, u \geq 0, v \geq 0 \end{aligned}$$

$$\begin{array}{c|c|c} T_0 & x & 1 \\ \hline s = & -A & b \\ \hline z_P = & c^\top & 0 \end{array} \quad \text{bzw.} \quad \begin{array}{c|c|c} T_0 & u & 1 \\ \hline v = & A^\top & c \\ \hline -z_D = & b^\top & 0 \end{array}$$

Beide Schemata sind (gewissermaßen) zueinander transponiert. Das duale Simplexverfahren für (P) kann als primales Simplexverfahren für (D) interpretiert werden.

3.5 Transportoptimierung

3.5.1 Problemstellung

Zur Erinnerung: Es gebe Erzeuger $i \in I = \{0, \dots, r\}$ und Verbraucher $k \in K = \{1, \dots, s\}$. Weiterhin seien die Kosten c_{ik} für den Transport einer Einheit von i nach k sowie der Vorrat $a_i > 0$ und der Bedarf $b_k > 0$ für alle $i \in I$ und $k \in K$ bekannt. Wie ist der gesamte Transport kostenminimal zu gestalten.

Als Variablen verwenden wir die Transportmenge x_{ik} von i nach k .

$$\begin{aligned} z = \sum_{i \in I} \sum_{k \in K} c_{ik} x_{ik} \rightarrow \min & \quad \text{bei} \quad \sum_{k \in K} x_{ik} = a_i \quad (i \in I) \\ & \quad \sum_{i \in I} x_{ik} = b_k \quad (k \in K) \\ & \quad x_{ik} \geq 0 \quad (i, k) \in I \times K \end{aligned} \quad (3.12)$$

Mit

$$\begin{aligned} x &= (x_{11}, x_{12}, \dots, x_{1s}, x_{21}, \dots, x_{rs})^\top \\ c &= (c_{11}, c_{12}, \dots, c_{1s}, c_{21}, \dots, c_{rs})^\top \\ \bar{b} &= (a_1, \dots, a_r, b_1, \dots, b_s)^\top \end{aligned}$$

hat (3.12) die Form

$$z = c^\top x \rightarrow \min \quad \text{bei} \quad Ax = \bar{b}, x \geq 0$$

Bemerkung 3.6

Das Transportproblem ist eine sehr spezielle Optimierungsaufgabe. Die Koeffizientenmatrix

$$A = \left(\begin{array}{ccc|ccc|ccc} 1 & 1 & \cdots & 1 & & & & & \\ & & & & 1 & 1 & \cdots & 1 & \\ \hline & & & & & & & & 1 & 1 & \cdots & 1 \\ 1 & & & & 1 & & & & 1 & & & \\ \hline & & & & & & & & & & & \\ & & & & & & & & & & \ddots & \\ & & & & & & & & & & & 1 \end{array} \right) \in \mathbb{R}^{(r+s) \times (r \cdot s)}$$

ist schwach besetzt. Insbesondere hat die Spalte von A , die zur Variablen x_{ik} gehört, die Gestalt $A^{ik} = \begin{pmatrix} e^i \\ e^k \end{pmatrix} \in \mathbb{R}^{r+s}$.

Satz 3.13

Das Transportproblem ist genau dann lösbar, wenn die Sättigungsbedingung

$$\sum_{i \in I} a_i = \sum_{k \in K} b_k \quad (3.13)$$

gilt.

Beweis. Wir zeigen zuerst, dass (3.13) äquivalent zu $G \neq \emptyset$ ist.

- Einerseits folgt aus $x \in G \neq \emptyset$ durch Summation der Gleichungsnebenbedingungen

$$\sum_{i \in I} a_i = \sum_{i \in I} \sum_{k \in K} x_{ik} = \sum_{k \in K} \sum_{i \in I} x_{ik} = \sum_{k \in K} b_k$$

- Gilt hingegen (3.13), so ist mit $\sigma := \sum_{i \in I} a_i = \sum_{k \in K} b_k$ ein zulässiger Punkt $x = (x_{ik})$ wie folgt definiert:

$$x_{ik} := \frac{a_i b_k}{\sigma}$$

Der zulässige Bereich G ist polyedrisch (und damit abgeschlossen) und ferner wegen $0 \leq x_{ik} \leq \min\{a_i, b_k\}$ beschränkt und somit kompakt. Mit dem Satz von Weierstraß¹ folgt dann die Lösbarkeit des Transportproblems. \square

Die Systemmatrix A besitzt für praxisrelevante Problemgrößen eine sehr große Anzahl an Einträgen, sodass die Anwendung des Simplexverfahrens im Allgemeinen nicht empfehlenswert ist; insbesondere deshalb, weil dieses die Struktur von A nicht mit einbezieht.

Zur Lösung des Transportproblems hat sich daher ein Verfahren etabliert, das auch die duale Aufgabe

$$w := a^\top u + b^\top v \rightarrow \max \text{ bei } A^\top \begin{pmatrix} u \\ v \end{pmatrix} \leq c, u \in \mathbb{R}^r, v \in \mathbb{R}^s \quad (3.14)$$

¹Die Zielfunktion ist linear, d.h. stetig, auf einer kompakten Menge G .

bzw.

$$w := \sum_{i \in I} a_i u_i + \sum_{k \in K} b_k v_k \rightarrow \max \text{ bei } u_i + v_k \leq c_{ik} \quad (u_i, v_k \in \mathbb{R}, i \in I, k \in K) \quad (3.15)$$

Satz 3.14 (Optimalitätskriterium)

Sei $x \in G$, d.h. x ist zulässiger Transportplan, dann gilt

$$x \text{ optimal} \Leftrightarrow \exists u \in \mathbb{R}^r, v \in \mathbb{R}^s \text{ mit } u_i + v_k \leq c_{ik}, x_{ik} \cdot (c_{ik} - u_i - v_k) = 0 \quad \forall i \in I, k \in K$$

Beweis. Nach dem Charakterisierungssatz gilt: $x \in G$ ist genau dann optimal, wenn duale Variablen $u \in \mathbb{R}^r$ und $v \in \mathbb{R}^s$ existieren, sodass (u, v) dual zulässig ist und die Komplementaritätsbedingungen gelten. \square

Aussage 3.15

Der Rang von A ist $|I| + |K| - 1 = r + s - 1$.

Beweis. Einerseits sind die Spalten $A^{11}, \dots, A^{1s}, A^{21}, A^{31}, \dots, A^{r1}$ von A linear unabhängig, d.h. $\text{rg}(A) \geq r + s - 1$. Andererseits ist die Summe der ersten r Zeilen identisch mit der Summe der letzten s Zeilen. Somit ist der Rang von oben beschränkt mit $\text{rg}(A) \leq r + s - 1$. \square

Folgerung 3.16

Jede Ecke des zulässigen Bereichs G hat höchstens $r + s - 1$ positive Komponenten.

Definition 3.4

Eine Folge von Zellen (Indexpaaren) $(i_1, k_1), (i_2, k_1), (i_2, k_2) \dots (i_\ell, k_\ell), (i_1, k_\ell), (i_1, k_1)$ mit $i_\nu \neq i_\mu, k_\nu \neq k_\mu$ für $\nu \neq \mu$ heißt **Zyklus** (der Länge 2ℓ).

Beispiel 3.5

Im folgenden Schema ist ein Zyklus der Länge $2\ell = 8$ abgebildet:

i/k	1	2	3	4	5
1	*		*		
2		*			*
3	*				*
4		*	*		

Dieses Beispiel spielt eine wichtige Rolle bei der Feststellung, ob ein gegebener Transportplan eine Ecke von G ist.

Aussage 3.17

- (i) Sei J eine Menge von Zellen. Gilt $|J| \geq r + s$, so enthält J mindestens einen Zyklus.
- (ii) Sei $x = (x_{ik})$ ein zulässiger Transportplan. x ist genau dann eine Ecke von G , wenn $J_+ := \{(i, k) : x_{ik} > 0\}$ keinen Zyklus enthält.

Beweis. vielleicht in der Übung — oder auch nicht. \square

3.5.2 Erzeugung eines ersten Transportplans

Dieser Teil entspricht der ersten Phase des Simplexverfahrens, d.h. also der Bestimmung einer Startecke. Gemäß der vorherigen Beobachtungen genügt es einen zyklensfreien zulässigen Transportplan zu finden. Hierfür können unterschiedliche Methoden genutzt werden.

Nordwest-Ecken-Regel: Die jeweilige noch nicht belegte Nordwest-Zelle wird mit maximaler Transportmenge belegt.

Regel der minimalen Kosten: In jedem Schritt wird eine noch nicht belegte Zelle, die minimale Kosten hat, mit maximaler Transportmenge belegt.

Methode von Vogel: Bestimme in jeder Zeile und Spalte die Differenz der zwei kleinsten Kostenkoeffizienten der noch freien Zellen. Wähle dann eine Zeile/Spalte mit maximaler Differenz und belege die Zelle mit kleinsten Kosten.

Darstellung der Inputdaten oder zulässigen Punkte in folgenden Schemata:

C	b_1	b_2	\dots	b_s
a_1	c_{11}	c_{12}	\dots	c_{1s}
\vdots	\vdots	\vdots	\ddots	\vdots
a_r	c_{r1}	c_{r2}	\dots	c_{rs}

Tabelle 3.1: Inputdaten

X	b_1	b_2	\dots	b_s
a_1	x_{11}	x_{12}	\dots	x_{1s}
\vdots	\vdots	\vdots	\ddots	\vdots
a_r	x_{r1}	x_{r2}	\dots	x_{rs}

Tabelle 3.2: Transportplan

Beispiel 3.6

Gegeben Sei das folgende Transportproblem:

C	12	5	6	7	7
4	12	6	10	9	5
19	10	16	17	3	7
14	4	11	5	8	10

Man erhält folgende Startecken:

x_{NW}	12 8	5 0	6 0	7 0	7 9
0	4	0	0	0	0
0 6 11 19	8	5	6	0	0
0 7 14	0	0	0	7	7
x_{NW}	12 8	5 0	6 0	7 0	7 9
0	4	0	0	0	0
0 6 11 19	8	5	6	0	0
0 7 14	0	0	0	7	7

Zielfunktionswert: $z(x_{NW}) = 4 \cdot 12 + 8 \cdot 10 + 5 \cdot 16 + 6 \cdot 17 + 7 \cdot 8 + 7 \cdot 10 = 436$

X_{NW}	12	5	6	7 0	7 3
0 4	0	0	0	0	$\boxed{4}^3$
0 12 10	0	$\boxed{5}$	$\boxed{4}$	$\boxed{7}^1$	$\boxed{3}$
0 2 14	$\boxed{12}^2$	0	$\boxed{2}^4$	0	0

Zielfunktionswert: $z(x_{MK}) = 268$

X	0	5	6	7	7
4		4			
19		1	4	7	7
14	12		2		

Zielfunktionswert: $z(x_V) = 236$

Je nach Qualität der Startlösung können unterschiedlich viele Iterationen des Transportalgorithmus vonnöten sein.

3.5.3 Der Transportalgorithmus

Ausgehend von einer Startlösung berechnet der Algorithmus zunächst ein Paar (u, v) dualer Variablen und prüft dann die Optimalität mit Satz 3.14. Liegt keine Optimalität vor, wird ein neuer Plan erzeugt.

Vorgehensweise:

- (1) Bestimme einen zulässigen, zyklensfreien Transportplan X_0 mit genau $r + s - 1$ markierten Basiszellen. (Diese bilden dann die Menge $J_B = J_B(X_0)$.)
- (2) Bestimme für den aktuellen Plan X die zugehörigen dualen Variablen u_i und v_k aus dem Gleichungssystem

$$u_i + v_k = c_{ik} \quad (i, k) \in J_B = J_B(X) \quad (3.16)$$

- (3) Berechne für alle $(i, k) \notin J_B$ die Koeffizienten $w_{ik} = c_{ik} - u_i - v_k$. Falls $w_{ik} \geq 0$ für alle Zellen ist, dann ist X optimal. Andernfalls wähle man eine Zelle (p, q) mit $w_{pq} = \min \{w_{ik} : i \in I, k \in K\} < 0$.
- (4) Markiere (p, q) im Schema von X , bestimme den (eindeutigen) Zyklus J_{pq} in $J_B \cup \{(p, q)\}$ und markiere abwechselnd die Zellen in J_{pq} mit "+" und "-". Sei J_{pq}^- die Menge der mit "-" gekennzeichneten Zellen.
- (5) Ermittle $\delta = x_{gh} := \min \{x_{ik} : (i, k) \in J_{pq}^-\}$ und aktualisiere den Plan X gemäß

$$X^{\text{neu}} := (x_{ik}^{\text{neu}}) \quad \text{mit} \quad x_{ik}^{\text{neu}} := \begin{cases} x_{ik} + \delta & \text{falls } (i, k) \in (J_{pq} \cup \{(g, h)\}) \setminus J_{pq}^- \\ x_{ik} - \delta & \text{falls } (i, k) \in J_{pq}^- \\ x_{ik} & \text{sonst} \end{cases}$$

Aktualisiere die Menge der Basiszellen

$$J_B^{\text{neu}} := (J_B \cup \{(p, q)\}) \setminus \{(g, h)\}$$

und gehe zu Schritt 2.

Bemerkung 3.7

Aufgrund von $|J_B| = r + s - 1$ ist das in Schritt 2 zu lösende Gleichungssystem (zur Ermittlung von u und v) unterbestimmt. Eine der Variablen kann also beliebig festgelegt werden. Die in Schritt 3 bestimmten Werte w_{ik} sind jedoch unabhängig von dieser Wahl.

Im gesamten Algorithmus gilt stets $w_{ik} = 0$ für die aktuellen Basiszellen $(i, k) \in J_B$ (per Konstruktion in Schritt 2), diese beeinflussen den Optimalitätstest in Schritt 3 also nicht. Daher kann zur Darstellung das folgende komprimierte Schema genutzt werden:

T	v_1	v_2	\dots	v_s
u_1	x_{11}	w_{12}	\dots	w_{1s}
u_2	w_{21}	w_{22}	x_{23}	w_{2s}
\vdots	\vdots	\vdots	\vdots	\vdots
u_r	w_{r1}	x_{r2}	\dots	w_{rs}

Beispiel 3.7 (Fortsetzung von Beispiel 3.6)

Gegeben Sei das Problem

C	12	5	6	7	7
4	12	6	10	9	5
19	10	16	17	3	7
14	4	11	5	8	10

Mit der Minimale-Kosten-Regel haben wir bereits den Plan X_0 bestimmt:

X_0	12	5	6	7	7
4	0	0	0	0	4
19	0	5	4	7	3
14	12	0	2	0	0

Bestimmung der dualen Variablen (Potenziale) u_i und v_k

T_0	$v_1 = 16$	$v_2 = 16$	$v_3 = 17$	$v_4 = 3$	$v_5 = 7$
$u_1 = -2$	-2	-8	-5	8	4
$u_2 = 0$	-6	5	4	7	3
$u_3 = -12$	12	7	2	17	15

$$5 : \underbrace{u_2}_{=0} + v_2 = c_{22} = 16 \Rightarrow v_2 = 16$$

$$-12 : u_3 + \underbrace{v_3}_{=17} = c_{33} = 5 \Rightarrow u_3 = c_{33} - 17 = -12$$

Dieser Plan ist nicht optimal, da negative Einträge w_{ik} existieren. Wir wählen also den eindeutig

bestimmten Zyklus $-8 \rightarrow 4 \rightarrow 3 \rightarrow 5 \rightarrow 8$ und geben alternierende "Vorzeichen", d.h. $-8^+ \rightarrow 4^- \rightarrow 3^+ \rightarrow 5^- \rightarrow 8^+$. Wir wählen das kleinste mit einem "-" markierte Zellenelement des Zyklus: $\delta = \min \{x_{ik} : (i, k) \in J_{pq}^-\} = 4$.

Ein neuer Plan ergibt sich nun mit

X_1					
		4			0
		1	4	7	7
	12		2		

Achtung: $x_{21} = 4$ war vorher nicht in der Basis (also $x_{21} = 0$) und somit $x_{21}^{\text{neu}} = x_{21} + \delta = 4$.

Bestimmung der Potenziale u_i und v_k für X_1 :

T_1	$v_1 = 16$	$v_2 = 16$	$v_3 = 17$	$v_4 = 3$	$v_5 = 7$
$u_1 = -10$	6	4	4	16	8
$u_2 = 0$	-6	1	4	7	7
$u_3 = -12$	12	7	2	17	15

Auch dieses Tableau ist noch nicht optimal. Wir erkennen den Zyklus $-6^+ \rightarrow 12^- \rightarrow 2^+ \rightarrow 4^-$.

Ein neuer Plan ergibt sich zu

X_2					
		4			
	4	1		7	7
	8		6		

mit den Potenzialen

T_2	$v_1 = 10$	$v_2 = 16$	$v_3 = 11$	$v_4 = 3$	$v_5 = 7$
$u_1 = -10$	12	4	9	16	8
$u_2 = 0$	4	1	6	7	7
$u_3 = -6$	8	1	6	11	9

Alle $w_{ik} \geq 0$, d.h. der das Tableau ist optimal und X_2 ist eine Lösung der gegebenen Optimierungsaufgabe. Es gilt $z(X_2) = 212$.

Kapitel 4

DISKRETE OPTIMIERUNG

In diesem Kapitel befassen wir uns mit Techniken zur Lösung ganzzahliger Optimierungsaufgaben. Dabei dürfen einige oder gar alle Variablen diskrete Werte annehmen. Somit entfällt eine Argumentation über Ableitung, zulässige Richtungen etc. Ganzzahlige Optimierungsaufgaben sind also "schwieriger" als die zugehörige stetige Relaxation. Dennoch kann, in einigen Fällen, das Lösen diskreter Aufgaben auch zur effizienten Lösung stetiger Aufgaben beitragen, wie folgendes Beispiel verdeutlicht.

4.1 Spaltengenerierung

Wir betrachten die stetige Relaxation des Bin-Packing-Problems (vgl. Abschnitt 1.3.2). Zur Erinnerung: Es sind b_i Teile der Länge ℓ_i ($i = 1, \dots, m$) in möglichst wenige Behälter der Kapazität L zu packen.

- Packungsvarianten: $a^j = (a_1^j, \dots, a_m^j)^\top \in \mathbb{Z}_+^m$ mit $\ell^\top a^j \leq L$ ($j \in J$)
 - Variablen: x_j beschreibt Häufigkeit, wie oft Variante a^j genutzt wird.
- $$z = \sum_{j \in J} x_j \rightarrow \min \quad \text{bei} \quad \sum_{j \in J} a_i^j \cdot x_j = b_i \quad (i \in I) \quad \text{und} \quad x_j \geq 0 \quad (j \in J)$$

Grundsätzlich ist diese Aufgabe mit dem Simplexverfahren lösbar, jedoch gibt es im Allgemeinen exponentiell viele Variablen, sodass pro Austauschschritt ein großer Aufwand entstünde.

Wir können uns hierbei zu Nutze machen, dass alle Spalten der Systemmatrix A eine gemeinsame Struktur aufweisen:

$$a^j \text{ ist Spalte von } A \Leftrightarrow a^j \in \mathbb{Z}_+^m \text{ und } \ell^\top a^j \leq L$$

Offenbar gilt hier $c = e = (1, \dots, 1)^\top$, sodass für eine gewählte Basismatrix A_B in Schritt 2 des Simplexalgorithmus folgendes zu bestimmen wäre:

$$\bar{q} := \min_{j \in J_N} q_j \quad \text{mit} \quad q_j = c_j - d^\top a^j = 1 - d^\top a^j, \quad a^j \in \mathbb{Z}_+^m, \ell^\top a^j \leq L$$

wobei $d^\top := c_B^\top A_B^{-1}$. In Schritt 2 wäre folglich die Aufgabe

$$1 - d^\top a^j = q_j \rightarrow \min \quad \text{bei} \quad \ell^\top a^j \leq L \text{ und } a^j \in \mathbb{Z}_+^m$$

bzw.

$$d^\top a^j \rightarrow \max \quad \text{bei} \quad \ell^\top a^j \leq L, a^j \in \mathbb{Z}_+^m$$

zu lösen. Gilt $q_j^* < 0$, so liegt keine Optimalität vor und eine zugehörige Lösung $a^{j,*}$ wäre in die Basismatrix aufzunehmen. Gilt $q_j^* \geq 0$, so sind wir fertig.

4.2 Die Methode Branch & Bound

Branch & Bound (B&B) ist eine sehr flexible Technik, um exakte Lösungsverfahren für Probleme der diskreten Optimierung zu entwickeln. Anschaulich betrachtet wird dabei eine schwierige Optimierungsaufgabe sukzessiv in Teilprobleme zerlegt, die wiederum "leicht" (näherungsweise) gelöst werden können und somit zur Lösung des Gesamtproblems beitragen. Näherungslösungen erhält man dabei oftmals mithilfe geeigneter Relaxationen.

4.2.1 Grundlagen

Wir betrachten das Anfangsproblem

$$f(x) \rightarrow \min \text{ bei } x \in E \cap D \quad (P_0)$$

und eine zugehörige Relaxation

$$g(x) \rightarrow \min \text{ bei } x \in E \quad (Q)$$

wobei $g(x) \leq f(x)$ auf $D \cap E$ gilt.

Prinzip der B&B-Methode

Die Menge E wird durch Separation in Teilmengen E_i mit $i \in I$ zerlegt. Dadurch entstehen **Teilprobleme**

$$f(x) \rightarrow \min \text{ bei } x \in D \cap E_i \quad (P_i)$$

Jedem dieser Teilprobleme (P_i) soll nun eine Zahl $b(P_i)$, genannt **untere Schranke**, zugeordnet werden, sodass gilt

- (a) $b(P_i) \leq \min \{f(x) : x \in D \cap E_i\}$
- (b) $b(P_i) = f(\hat{x})$ falls $D \cap E = \{\hat{x}\}$
- (c) $b(P_i) \leq b(P_j)$ falls $E_j \subset E_i$

Eine geeignete Möglichkeit besteht darin, z.B. die stetige Relaxation der Teilprobleme (P_i) zu betrachten, d.h.

$$b(P_i) := \begin{cases} \min \{g(x) : x \in E_i\} & \text{falls } |E_i \cap D| > 1 \\ f(\hat{x}) & \text{falls } |E_i \cap D| = 1 \\ +\infty & \text{falls } E_i \cap D = \emptyset \end{cases}$$

4.2.2 Allgemeiner B&B-Algorithmus

Bezeichne mit R die Menge der noch zu bearbeitenden Teilprobleme ("Restmenge") und mit \bar{z} den Zielfunktionswert der bisher besten gefundenen zulässigen Lösung $\bar{x} \in D \cap E$.

Schritt 0: Initialisierung — Bestimme $b(P_0)$.

- (a) Falls $\bar{x} \in D \cap E$ bekannt ist mit $f(\bar{x}) = b(P_0)$, dann **STOP**.
- (b) Setze $R := \{P_0\}$ und $\bar{z} := +\infty$ oder $\bar{z} = f(x)$, wenn ein $x \in D \cap E$ bekannt ist.

Schritt 1: Abbruchtest — Falls $R \neq \emptyset$, dann **STOP**. Falls $\bar{z} = +\infty$, dann ist (P_0) nicht lösbar (leerer zulässiger Bereich), andernfalls ist \bar{x} Lösung von (P_0) .

Schritt 2: Strategie — Wähle entsprechend einer Auswahlstrategie ein $P_i \in R$ und setze $R := R \setminus \{P_i\}$.

Schritt 3: Zerlegung ("branch") — Zerlege P_i durch Separation in endlich viele Teilprobleme $P_{i,1}, \dots, P_{i,k_i}$. Setze $j := 1$.

Schritt 4: Schranken- und Dominanztests ("bound")

- (a) Berechne $b(P_{i,j})$. Falls dabei ein $\tilde{x} \in D \cap E$ gefunden wurde mit $f(\tilde{x}) < \bar{z}$, setze $\bar{x} := \tilde{x}$ und $\bar{z} := f(\tilde{x})$.
- (b) Falls $b(P_{i,j}) < \bar{z}$, dann setze $R := R \cup \{P_{i,j}\}$. Falls $j < k_i$, setze $j := j + 1$ und gehe zu (a).
- (c) Setze $R := R \setminus \{P_k\}$ für alle $P_k \in R$ mit $b(P_k) \geq \bar{z}$.

Gehe zu Schritt 1.

Bemerkung

- (1) Die Endlichkeit des Verfahrens ist zu sichern, z.B. durch $|E_{i,j} \cap D| \leq |E_i \cap D|$ für alle j (falls $E_i \cap D$ endlich ist) oder durch $b(P_{i,j}) > b(P_i) + \varepsilon$ mit $\varepsilon > 0$ für alle j und i .
- (2) Das B&B-Verfahren kann mithilfe eines Verzweigungsbaumes veranschaulicht werden.
- (3) In Schritt 2 können verschiedene Auswahlstrategien gewählt werden, z.B.
 - **Minimalsuche** (best bound search): wähle $P_i \in R$ mit $b(P_i) \leq b(P_k)$ für alle $P_k \in R$.
 - **Tiefensuche** (depth-first search, LIFO): wähle $P_i \in R$ mit kleinstem Schrankenwert unter allen Teilproblemen mit maximaler Verzweigungstiefe.
 - **Breitensuche** (breadth-first-search, FIFO): wähle $P_i \in R$ mit kleinstem Schrankenwert unter allen Teilproblemen mit minimaler Verzweigungstiefe.

4.2.3 Beispiele für B&B-Verfahren

Das 0/1-Rucksackproblem

Zur Erinnerung: Gegeben seien ganze Zahlen $c_i > 0$, $0 < a_i < b$ für $i \in I := \{1, \dots, n\}$

$$f(x) = c^\top x \rightarrow \max \text{ bei } a^\top x \leq b, \quad x \in \{0, 1\}^n \quad (\text{P})$$

$$f(x) = c^\top x \rightarrow \max \text{ bei } a^\top x \leq b, \quad c \in [0, 1]^n \quad (\text{Q})$$

Hier gilt also $E = \{x \in \mathbb{R}^n : a^\top x \leq b, 0 \leq x \leq 1, i \in I\}$ und $D = \mathbb{B}^n = \{0, 1\}^n$.

Bemerkung 4.1

Die stetige Relaxation (Q) besitzt unter der Voraussetzung

$$\frac{c_i}{a_i} \geq \frac{c_{i+1}}{a_{i+1}} \quad \text{für } 1 \leq i \leq n$$

die Lösung

$$\hat{x}_i = 1 \quad (i = 1, \dots, k) \quad \hat{x}_{k+1} = \frac{b - \sum_{i=1}^k a_i}{a_{k+1}} \quad \hat{x}_i = 0 \quad i = k+2, \dots, n \quad (\text{R})$$

mit $k := \max \left\{ j \in I : \sum_{i=1}^j a_i \leq b \right\}$.

Bemerkung. Wir sortieren also abfallend nach Nutzen pro Volumen und packen dann soviel wie möglich in den Rucksack (k Elemente). Dann füllen wir den Restplatz noch mit (einem Anteil von) dem nächsten Element auf ($k+1$ -tes Element), alles danach können wir nicht mehr mitnehmen.

Innerhalb des Verzweigungsbaums ergeben sich die folgenden Teilprobleme (für bereits fixierte Variablen \bar{x}_i , $i \in I_k \subseteq I$).

$$\sum_{i \in I_k} c_i \bar{x}_i + \sum_{i \notin I_k} c_i x_i \rightarrow \max \text{ bei } \sum_{i \notin I_k} a_i x_i \leq b - \sum_{i \in I_k} a_i \bar{x}_i, \quad i \notin I_k, x_i \in \mathbb{B} \quad (P_k(\bar{x}))$$

$$\sum_{i \in I_k} c_i \bar{x}_i + \sum_{i \notin I_k} c_i x_i \rightarrow \max \text{ bei } \sum_{i \notin I_k} a_i x_i \leq b - \sum_{i \in I_k} a_i \bar{x}_i, \quad i \notin I_k, x_i \in [0, 1] \quad (Q_k(\bar{x}))$$

Beachte: Da es sich um eine Maximierungsaufgabe handelt, werden im B&B-Algorithmus *obere* Schranken $b(P_k(\bar{x}))$ benötigt. Diese gewinnen wir aus den Optimalwerten der stetigen Relaxation $Q_k(\bar{x})$.

Beispiel 4.1

Gegeben sei das binäre Rucksackproblem

$$\begin{aligned} z = c^\top x &= 8x_1 + 16x_2 + 20x_3 + 12x_4 + 6x_5 + 10x_6 + 4x_7 \rightarrow \max \\ \text{bei } a^\top x &= 3x_1 + 7x_2 + 9x_3 + 6x_4 + 3x_5 + 5x_6 + 2x_7 \leq 17 = b, \quad x_i \in \{0, 1\}, i = 1, \dots, 7 \end{aligned} \quad (\text{P})$$

- Die korrekte Sortierung liegt bereits vor.
- Wurzelknoten $(P) = (P_0)$: Die stetige Relaxation besitzt die Lösung $x_1 = x_2 = 1$ und $x_3 = \frac{7}{9}$ sowie $x_4 = \dots = x_7 = 0$. Somit ist $b(P_0) = \lfloor 8 + 16 + 20 \cdot \frac{7}{9} \rfloor = 39$. Die Abrundung ist dabei erlaubt, da $c^\top x \in \mathbb{Z}$ für alle zulässigen Punkte von (P) . Ein zulässiger Punkt für (P) ist gegeben durch $\bar{x}_1 = \bar{x}_2 = \bar{x}_4 = 1$, $\bar{x}_i = 0$ sonst. Dabei ist $z(\bar{x}) = 8 + 16 + 12 = 36 =: \bar{z}$. Wegen $36 < 39$ muss weiter verzweigt werden.
- Verzweigung: $x_3 = 0$ vs. $x_3 = 1$.
 - ▷ Teilproblem: $(P_1) = (P_{0,1})$. Setzt man $x_3 = 0$, so hat die stetige Relaxation die Lösung $x_1 = x_2 = x_4 = 1$, $x_5 = \frac{1}{3}$ und $x_6 = x_7 = 0$. Somit ist $b(P_1) = \lfloor 8 + 16 + 12 + 6 \cdot \frac{1}{3} \rfloor = 38$. Ein daraus ableitbarer Punkt ist gegeben durch $\bar{x}_1 = \bar{x}_2 = \bar{x}_4 = 1$ mit $z = 36$, d.h. \bar{z} muss nicht aktualisiert werden.
 - ▷ $(P_2) = (P_{0,2})$. Setzt man $x_3 = 1$, so erhält man $x_1 = 1$, $x_2 = \frac{5}{7}$ mit $b = \lfloor 8 + 20 + 16 \cdot \frac{5}{7} \rfloor = 39$ und einen zulässigen Punkt für (P) durch $\bar{x}_1 = \bar{x}_3 = \bar{x}_5 = \bar{x}_7 = 1$ mit $\bar{z} = 38$, d.h. \bar{z} wurde verbessert.
 - ▷ Damit kann (P_1) abgeschlossen werden, da maximal noch der Zielfunktionswert 38 möglich ist, der in (P_2) bereits erreicht worden ist.
- Verzweigung: $x_2 = 0$ vs. $x_2 = 1$.
 - ▷ Teilproblem $(P_3) = (P_{2,1})$. Setzt man $x_2 = 0$ (und $x_3 = 1$ von oben), dann hat die stetige Relaxation die Lösung $x_1 = 1$, $x_4 = \frac{5}{6}$ mit $b(P_3) = 38 = \bar{z}$, also sind wir hier fertig.
 - ▷ Teilproblem $(P_4) = (P_{2,2})$. Setzt man $x_2 = 1$ (und $x_3 = 1$) so folgt $x_1 = \frac{1}{3}$, also $b(P_4) = 38 = \bar{z}$, d.h. wir sind hier wieder fertig.
- Nun ist $R = \emptyset$ und wir haben eine Lösung gefunden:

$$x_1 = x_3 = x_5 = x_7 = 1 \quad \text{mit} \quad z = 38$$

Ganzzahlige lineare Optimierung nach Land/Doig/Dahin

Wir betrachten die ganzzahlige Optimierungsaufgabe

$$c^\top x \rightarrow \min \quad \text{bei } x \in D \cap E \tag{P}$$

mit $D = \mathbb{Z}^n$ und $E = E_0 = \{x \in \mathbb{R}^n : Ax = b, x \geq 0\}$, wobei alle Inputdaten (A, b, c) ganzzahlig sind. Die im Verlauf des Verfahrens zu betrachtenden Teilprobleme (P_i) haben die Form

$$c^\top x \rightarrow \min \quad \text{bei } x \in D \cap E_i \tag{P_i}$$

wobei E_i durch eine oder mehrere zusätzliche Ungleichungen aus E_0 entsteht. Sei x^{LP} eine Lösung der zu (P_i) gehörenden stetigen Relaxation

$$z(Q_i) = \min \{c^\top x : x \in E_i\} \tag{Q_i}$$

mit $x_j^{\text{LP}} \notin \mathbb{Z}$ für mindestens einen Index j . Dann kann der (gerundete) Optimalwert als Schranke $b(P_i)$ genutzt werden.

$$E_{i,1} = \left\{ x \in E_i : x_j \leq \left\lfloor x_j^{\text{LP}} \right\rfloor \right\} \quad (\text{P}_{i,1})$$

$$E_{i,2} = \left\{ x \in E_i : x_j \geq \left\lfloor x_j^{\text{LP}} \right\rfloor + 1 = \left\lceil x_j^{\text{LP}} \right\rceil \right\} \quad (\text{P}_{i,2})$$

Bemerkung 4.2

Das Runden des Optimalwertes einer Relaxation zur Schrankenbestimmung ist nur für $c \in \mathbb{Z}^n$ zulässig.

Beispiel 4.2

Betrachte

$$z = -7x_1 - 2x_2 \rightarrow \min \text{ bei } -x_1 + 2x_2 + x_4 = 4$$

$$5x_1 + x_2 + x_4 = 20, \quad x_1, \dots, x_n \in \mathbb{Z}_+$$

Die Relaxation ergibt sich durch $x_1, \dots, x_n \geq 0$.

■ Wurzelknoten:

T_1	x_1	x_2	1		T_3	x_4	x_3	1
$x_3 =$	1	-2	4	$x_1 \leftrightarrow x_4$	$x_2 =$	$-\frac{1}{11}$	$-\frac{5}{11}$	$\frac{40}{11}$
$x_4 =$	-5	-1	20	\dots	$x_1 =$	$-\frac{2}{11}$	$\frac{1}{11}$	$\frac{26}{11}$
$z =$	-7	-2	0	$x_2 \leftrightarrow x_3$	$z =$	$\frac{16}{11}$	$\frac{3}{11}$	$-\frac{332}{11}$

■ Verzweigung: nach x_2 , da $\min \left\{ 4 - \frac{40}{11}, \frac{40}{11} - 3 \right\} > \min \left\{ 4 - \frac{36}{11}, \frac{36}{11} - 3 \right\}$.

▷ 1. Teilproblem: $x_2 \geq 4$ (führe $s_2 \geq 0$ ein)

$$\begin{aligned} \Rightarrow s_2 &= x_2 - 4 \stackrel{\text{aus } T_3}{=} \left(-\frac{1}{11}x_4 - \frac{5}{11}x_3 + \frac{40}{11} \right) - 4 \\ &= -\frac{1}{11}x_4 - \frac{5}{11}x_3 - \frac{4}{11} < 0 \end{aligned}$$

Damit ist $x_2 \geq 4$ nicht möglich (leerer zulässiger Bereich) und dieser Fall muss nicht betrachtet werden.

▷ 2. Teilproblem: $x_2 \leq 3$ (führe $s_2 \geq 0$ ein)

$$\begin{aligned} s_2 &= 3 - x_2 = 3 - \left(-\frac{1}{11}x_4 - \frac{5}{11}x_3 + \frac{40}{11} \right) \\ &= \frac{1}{11}x_4 + \frac{5}{11}x_3 - \frac{7}{11} \end{aligned}$$

Füge dies ist T_3 ein:

T'_3	x_4	x_3	1		T_4	x_4	s_2	1
$x_2 =$	$-\frac{1}{11}$	$-\frac{5}{11}$	$\frac{40}{11}$	$s_2 \leftrightarrow x_3$	$x_2 =$	0	-1	3
$x_1 =$	$-\frac{2}{11}$	$\frac{1}{11}$	$\frac{26}{11}$		$x_1 =$	$-\frac{1}{5}$	$\frac{1}{5}$	$\frac{17}{5}$
$s_2 =$	$\frac{1}{11}$	$\frac{5}{11}$	$-\frac{7}{11}$		$x_3 =$	$-\frac{1}{5}$	$\frac{11}{5}$	$\frac{7}{5}$
$z =$	$\frac{16}{11}$	$\frac{3}{11}$	$-\frac{332}{11}$		$z =$	$\frac{7}{5}$	$\frac{3}{5}$	$-\frac{149}{5}$
Keller	$-\frac{1}{5}$	*	$\frac{7}{5}$					

- Verzweigung: x_1 (x_3 ebenso möglich)

▷ 3. Teilproblem: $x_1 \geq 4 \Rightarrow s_1 = x_1 - 4 = -\frac{1}{5}x_4 + \frac{1}{5}s_2 - \frac{3}{5}$

T'_4	x_4	s_2	1		T_5	x_4	s_1	1
$x_2 =$	0	-1	3	$s_1 \leftrightarrow s_2$ \rightarrow	$x_2 =$			0
$x_1 =$	$-\frac{1}{5}$	$\frac{1}{5}$	$\frac{17}{5}$		$x_1 =$			4
$x_3 =$	$-\frac{1}{5}$	$\frac{11}{5}$	$\frac{7}{5}$		$x_3 =$			3
$s_1 =$	$-\frac{1}{5}$	$\frac{1}{5}$	$\frac{3}{5}$		$s_2 =$			8
$z =$	$\frac{7}{5}$	$\frac{3}{5}$	$-\frac{149}{5}$		$z =$	2	3	-28

Damit haben wir zumindest *eine* ganzzahlige Lösung $z = -28$. Wir wissen jedoch noch nicht, ob es tatsächlich die optimale Lösung ist.

- ▷ 4. Teilproblem: $x_1 \leq 3 \Rightarrow s_1 = 3 - x_1 = \frac{1}{5}x_4 - \frac{1}{5}s_2 - \frac{2}{5}$. Dies fügt man zu T_4 hinzu. Ein dualer Simplexschritt führt dann zu

T_6	s_1	s_2	1
$x_2 =$			3
$x_1 =$			3
$x_3 =$			2
$x_3 =$			1
$z =$	2	3	-27

Dabei haben wir also eine ganzzahlige Lösung mit $z = -27$.

Insgesamt wissen wir also $x^* = (4, 0, 3, 0)$ mit $z^* = -28$ aus dem dritten Teilproblem.

Das Rundreiseproblem (Traveling Salesman Problem, TSP)

Gegeben seien n Orte, eine Kostenmatrix $C = (c_{ik}) \in \mathbb{R}^{n \times n}$, wobei c_{ik} die Entfernung (Zeit, Kosten, ...) von i nach k beschreibt.

Annahme: $c_{ii} = +\infty$ für alle $i \in I = \{1, \dots, n\}$. In einigen Anwendungen ist C auch symmetrisch.

Variablen: $x_{ik} \in \{0, 1\}$, $(i, k) \in I \times I$ mit $x_{ik} = 1 \Leftrightarrow$ man reist von i nach k

Optimierungsproblem:

$$z = \sum_{i \in I} \sum_{k \in I} c_{ik} x_{ik} \rightarrow \min \quad (4.1)$$

$$\text{bei } \sum_{i \in I} x_{ik} = 1 \quad (k \in I) \quad (4.2)$$

$$\sum_{k \in I} x_{ik} = 1 \quad (i \in I) \quad (4.3)$$

$$x_{ik} \in \{0, 1\} \quad (i, k) \in I \times I \quad (4.4)$$

$$\sum_{i, k} x_{ik} \in S \leq |S| - 1 \quad (S \subset I, 0 < |S|) \quad (4.5)$$

Die Bedingung (4.5) wird auch **Subtourelimitationsbedingung** (SEB) genannt. Die Bedingungen (4.1) bis (4.4) modellieren ein spezielles Transportproblem (das **Zuordnungsproblem**). Für das Problem (4.1) – (4.5) kann man auf folgende Weise Schranken erhalten:

- Lösung des (ganzzzahligen) Zuordnungsproblems
- stetige Relaxation von (4.1) – (4.5): löse zunächst das Zuordnungsproblem. Falls dabei Subtours entstehen, verbiete man diese mit geeigneten Bedingungen vom Typ (4.5) und löse danach das um diese Bedingung erweiterte Zuordnungsproblem.
- Zeilen- und Spaltenreduktion: Ermittlung einer zulässigen Lösung (u, v) des dualen Problems (der stetigen Relaxation des Zuordnungsproblems) mithilfe der folgenden Idee:

$$\begin{aligned} u_i &:= \min \{c_{ik} : k \in I\} & (i \in I) \\ v_i &:= \min \{c_{ik} - u_i : i \in I\} & (k \in I) \\ \Rightarrow w_{ik} = c_{ik} - u_i - v_k &\geq 0 & \forall (i, k) \in I \times I \text{ (duale Zulässigkeit)} \end{aligned}$$

Somit gilt

$$\begin{aligned} z &= \sum_{i \in I} \sum_{k \in I} c_{ik} x_{ik} \stackrel{(\star)}{=} \sum_{i \in I} \sum_{k \in I} \underbrace{w_{ik}}_{\geq 0} \underbrace{x_{ik}}_{\geq 0} + \sum_{i \in I} u_i + \sum_{k \in I} v_k \\ &\geq \sum_{i \in I} u_i + \sum_{k \in I} v_k & \text{(untere Schranke für } z) \end{aligned}$$

Im Schritt (\star) haben wir dabei $w_{ik} = c_{ik} - u_i - v_k$ und die Bedingungen (4.2) sowie (4.3) verwendet.

Die oben genannten Schrankenwerte unterscheiden sich (mitunter stark) hinsichtlich des numerischen Aufwands und der Güte der erhaltenen Näherungen. In dieser Vorlesung betrachten wir die dritte Variante.

Beispiel 4.3

Wir betrachten die Kostenmatrix

$C = (c_{ik})$						u_i
	∞	32	<u>22</u>	30	24	22
	10	∞	<u>3</u>	18	∞	3
	∞	<u>9</u>	∞	14	12	9
	16	10	7	∞	<u>6</u>	6
	15	19	15	<u>12</u>	∞	12
v_k	3	0	0	0	0	$b = 55$

Damit ist $b = \sum_i u_i + \sum_k v_k = 55$ eine untere Schranke für den Optimalwert.

Bemerkung 4.3

Die Schranke, die aus Zeilen- und anschließender Spaltenreduktion erhalten wird, weicht im Allgemeinen von der Schranke ab, die aus Spalten- und anschließender Zeilenreduktion gewonnen wird.

Unter Einbeziehung der reduzierten Kostenmatrix $D = (w_{ik})$ mit $w_{ik} = c_{ik} - u_i - v_k$ kann eine

Verzweigungs- und Auswahlstrategie formuliert werden: Dabei betrachten wir die Elemente mit $w_{ik} = 0$ und verzweigen gemäß $x_{ik} = 0$ vs. $x_{ik} = 1$.

- Die Belegung $x_{ik} = 0$ ist gleichbedeutend mit der Änderung des aktuellen Kostenwertes auf $+\infty$.
- Eingedenk¹ der Bedingungen (4.2) und (4.3) impliziert die Wahl $x_{ik} = 1$, dass $x_{jk} = 0$ für alle $j \neq i$ und $x_{i\ell} = 0$ für alle $\ell \neq k$ gelten muss. Für diese Indexpaare kann man die Kosten auf $+\infty$ erhöhen. Weiterhin muss die Subtour $i \rightarrow k \rightarrow i$ verhindert werden, d.h. es gilt $x_{ki} = 0$ und damit $w_{ki} = +\infty$. (Analog verfähre man gegebenenfalls mit längeren Subtours.) Infolge dieser Änderung der Kostenmatrix können im Anschluss weitere Zeilen- und Spaltenreduktionen ermöglicht werden, die zu verbesserte Schranken (in den entsprechenden Teilproblemen) führen können.

¹Alternativer Vorschlag: im Lichte der Bedingungen ...